

Projet 4

Segmentez des clients d'un site
e-commerce

Loridan Adrien



student machine learning
engineer



medium.com/@adrien.loridan



linkedin.com/in/adrien-loridan



github.com/loridan



olist

Observer pour connaître, connaître pour comprendre,
comprendre pour agir.

olist

Observer pour connaître, connaître pour comprendre,
comprendre pour agir.

Présentation

Olist propose une solution de vente sur les marketplaces en ligne pour les commerçants. Elle a pour objectif de mieux communiquer auprès des acheteurs.

olist

Observer pour connaître, connaître pour comprendre,
comprendre pour agir.

Présentation

Olist propose une solution de vente sur les marketplaces en ligne pour les commerçants. Elle a pour objectif de mieux communiquer auprès des acheteurs.

Problème

Pouvons nous mieux connaître nos clients et mieux investir le budget dans nos actions marketing ?



Observer pour connaître, connaître pour comprendre,
comprendre pour agir.

Une solution envisagée par Olist...

Olist souhaite obtenir une segmentation de ses clients à l'aide de méthodes non supervisées sur ses propres données.

olist

Observer pour connaître, connaître pour comprendre,
comprendre pour agir.

avec une demande spécifique :

- décrire les segments
- évaluer la fréquence de mise à jour de la segmentation
- respecter la convention PEP8

Observer pour connaître, connaître pour comprendre,
comprendre pour agir.

Critères de segmentation

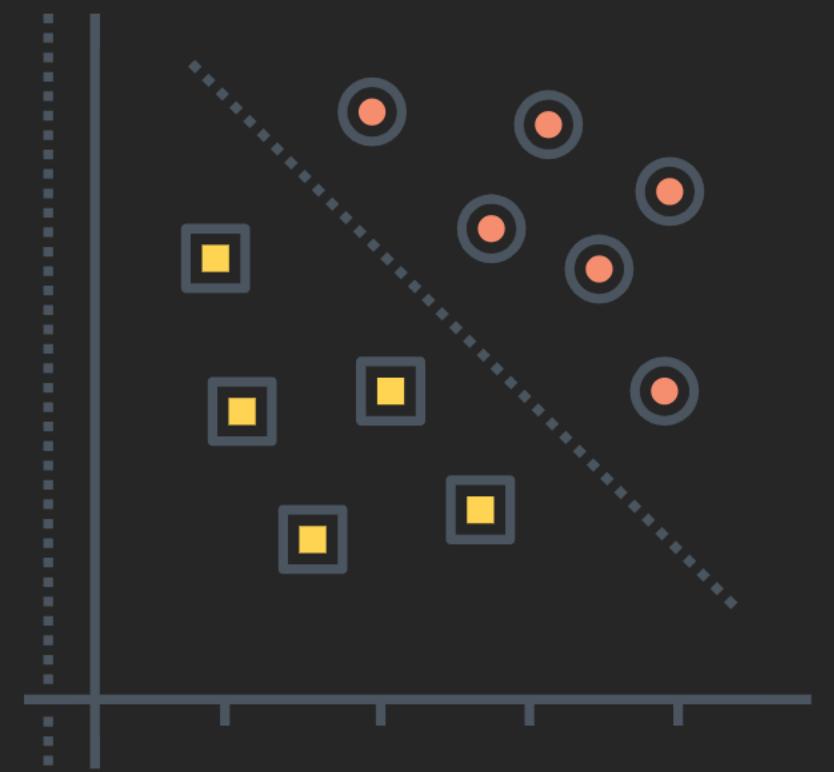
Segmenter, c'est donc créer des groupes composés de clients ayant des points communs identifiables :

- géographiques (géolocalisation, météo)
- démographiques (genre, age, nationalité)
- comportementales (nombre de visites, historique d'achat)

Observer pour connaître, connaître pour comprendre,
comprendre pour agir.

Critères de segmentation

- rule-based segmentation
- cluster-based segmentation (*envisagée par Olist*)



Observer pour connaître, connaître pour comprendre,
comprendre pour agir.

Segmenter sur 3 dimensions "RFM"

On extrait des données ces 3 critères pour chacun des clients :

- Récence : *date du dernier achat*
- Fréquence : *fréquence des achats*
- Montant : *somme des achats cumulés*

Observer pour connaître, connaître pour comprendre,
comprendre pour agir.

Segmenter sur 3 dimensions "RFM"

RFM is a method used for analyzing customer value.
It is commonly used direct marketing and has received particular attention in retail and professional services industries.

Technique simple et compréhensible pour définir un segment-cible prioritaire par les gens du business

Observer pour connaître, connaître pour comprendre,
comprendre pour agir.

Segmenter sur N dimensions

On extrait des données un maximum de critères pour chacun des clients.

Méthode compliquée et moins compréhensible mais permettant de découvrir d'autres segments profitables.

Observer pour connaître, connaître pour comprendre,
comprendre pour agir.

Respecter la PEP8

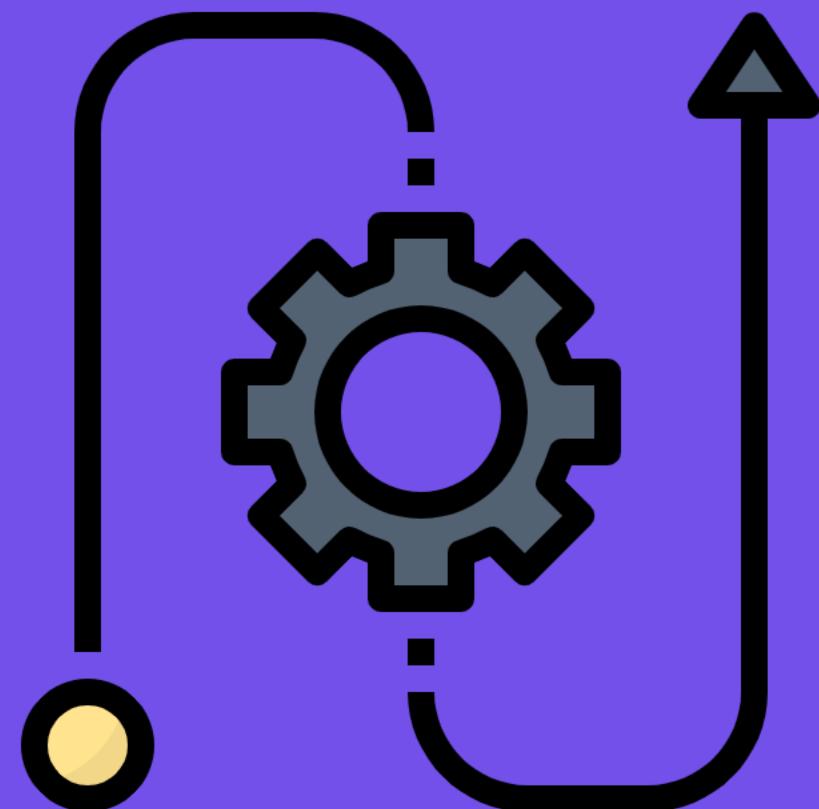
La PEP 8 définit des règles de développement communes entre développeurs.

Nous avons utilisé Pylint qui est un logiciel en ligne de commande pour analyser et corriger le code.



La science des données

Expérimentation



- 1 Collecter des données
- 2 Préparer et explorer les données
- 3 Segmenter

kaggle

**Lien de téléchargement**

kaggle.com/olistbr/brazilian-e-commerce

9 fichiers

olist_customers_dataset.csv (8.62 MB)

olist_geolocation_dataset.csv (58.44 MB)

olist_order_items_dataset.csv (14.72 MB)

olist_order_payments_dataset.csv (5.51 MB)

olist_order_reviews_dataset.csv (13.74 MB)

olist_orders_dataset.csv (16.84 MB)

olist_products_dataset.csv (2.27 MB)

olist_sellers_dataset.csv (170.61 KB)

product_category_name_translation.csv (2.55 KB)

olist

kaggle

**Quelle est la réglementation sur la protection de ces données ?**

Faible, contenu anonymisé sous licence NonCommercial (CC BY-NC-SA 4.0)

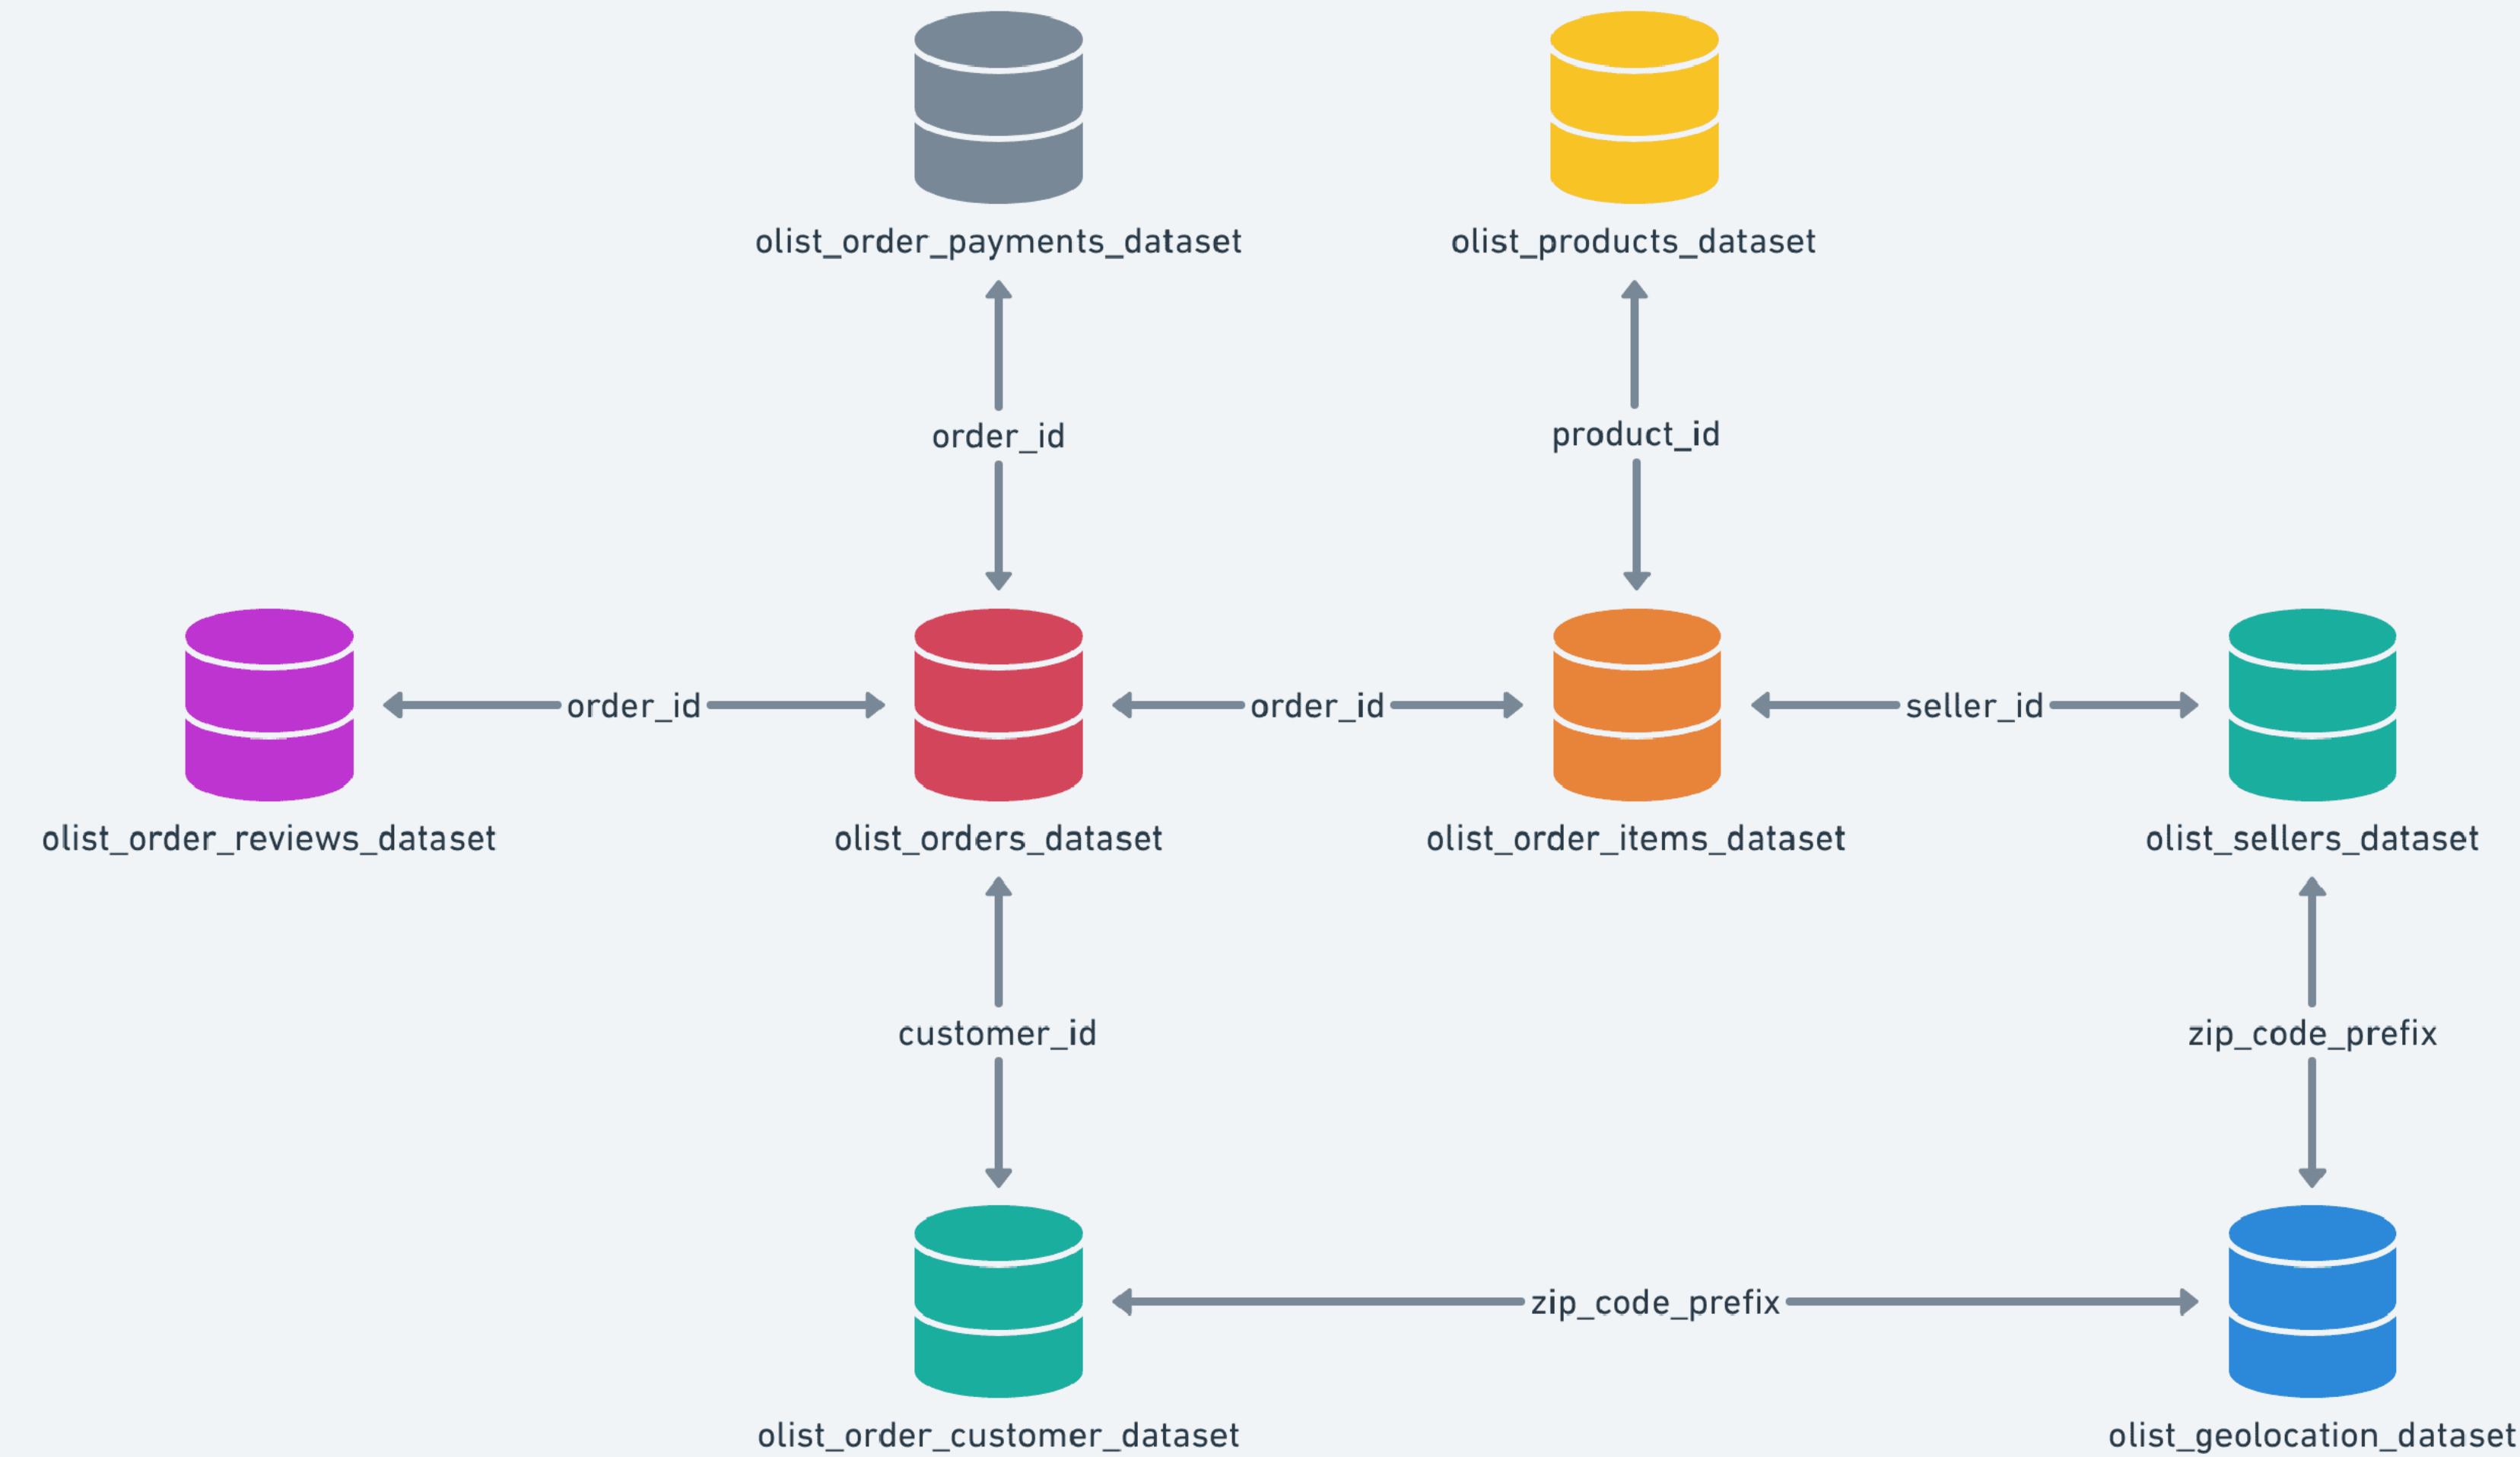
Où sont stockées les données?

Elles sont sur les serveurs distants publiques et sur notre ordinateur en sdd local

Quel est le type des données

Structurée

olist



olist



Nettoyage

Importer et observer les données

Identifier et traiter les doublons

Identifier et traiter les valeurs manquantes ('*review_comment_title*'...)

Convertir les timestamps ('*order_delivered_customer_date*'...)

Analyser les données avant assemblage



Assemblage pour segmentations

Merge

Feature engineering*

Visualisation des valeurs quantitatives

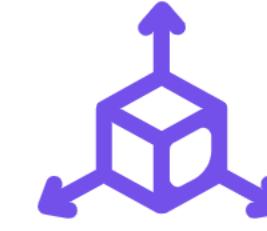
Export ("df_rfm.csv" et "df_customers.csv")



Feature engineering pour segmentation $N=3$ dimensions - RFM

- Nombre de jours depuis dernier achat / Récence
- Nombre d'ordres / Fréquence
- Somme des paiements / Montant

Feature engineering pour segmentation **N=105 dimensions**



- Nombre d'ordres / Fréquence
- Statistiques sur paiements (min, max, mean, sum)
- Ratio pour les différents moyens de paiement
- Statistiques produits achetés par ordre (mean)
- Nombre de comptes clients
- Statistiques sur notes laissées (min, max, mean)
- Ratio d'ordres pour chaque categories
- Ratio d'ordres pour differents types de produits
- Montant total dépensé par client pour differents types de produits (1-4)
- Statistiques sur délais de livraison (min, max, mean, sum)
- Ratio par buckets sur délais de livraison en jours ((0-3j] (3-7j] (7-14j] (14-maxj])
- Nombre de jours depuis dernier achat / Récence

Feature engineering : data augmentation

```
Entrée [53]: mapper_categories_to_four_types = {  
    'health_beauty' : 'convenience',  
    'computers_accessories' : 'shopping',  
    'auto' : 'shopping',  
    'bed_bath_table' : 'shopping',  
    'furniture_decor' : 'shopping',  
    'sports_leisure' : 'shopping',  
    'perfumery' : 'convenience',  
    'housewares' : 'shopping',  
    'telephony' : 'shopping',  
    'watches_gifts' : 'shopping',  
    'food_drink' : 'convenience',  
    'baby' : 'convenience'
```

Consumer products classification system



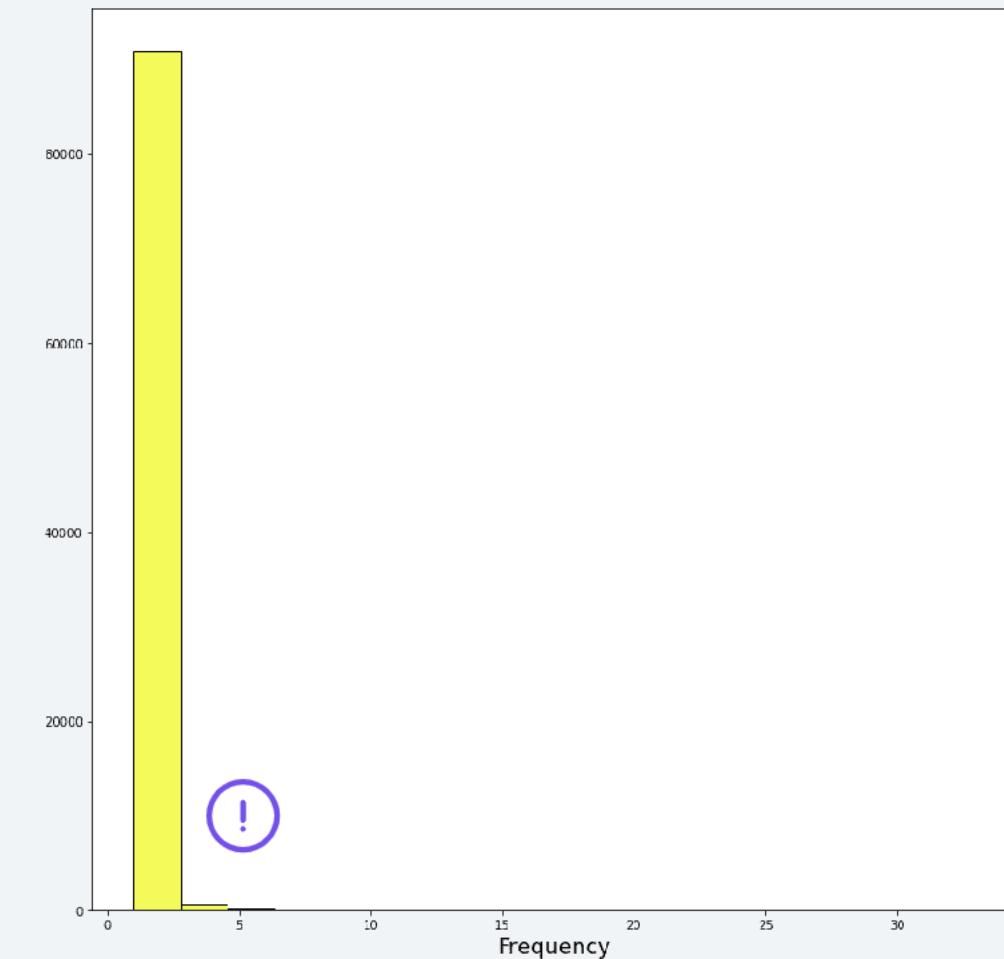
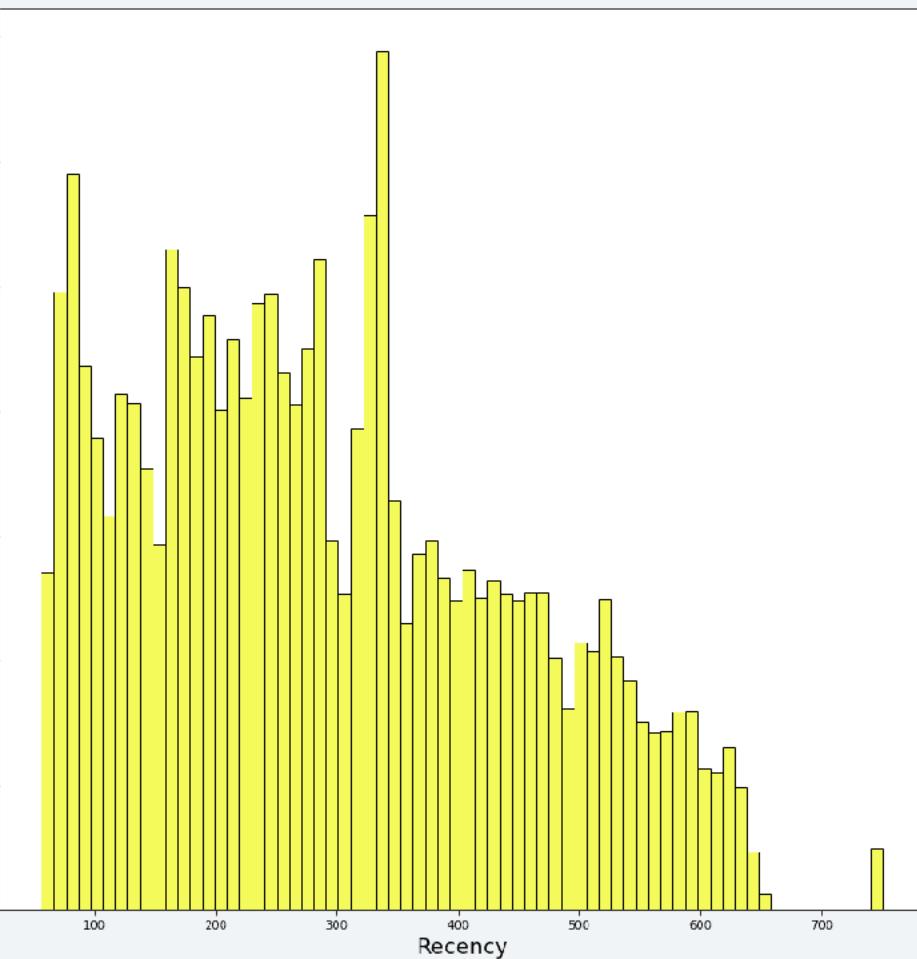
Cependant Olist ne vend pas de produits de type : 'Unsought products'

Journal of Marketing - "Retail Strategy and the Classification of Consumer Goods"
(<https://www.jstor.org/stable/1248582?seq=1>)

Distribution sur RFM

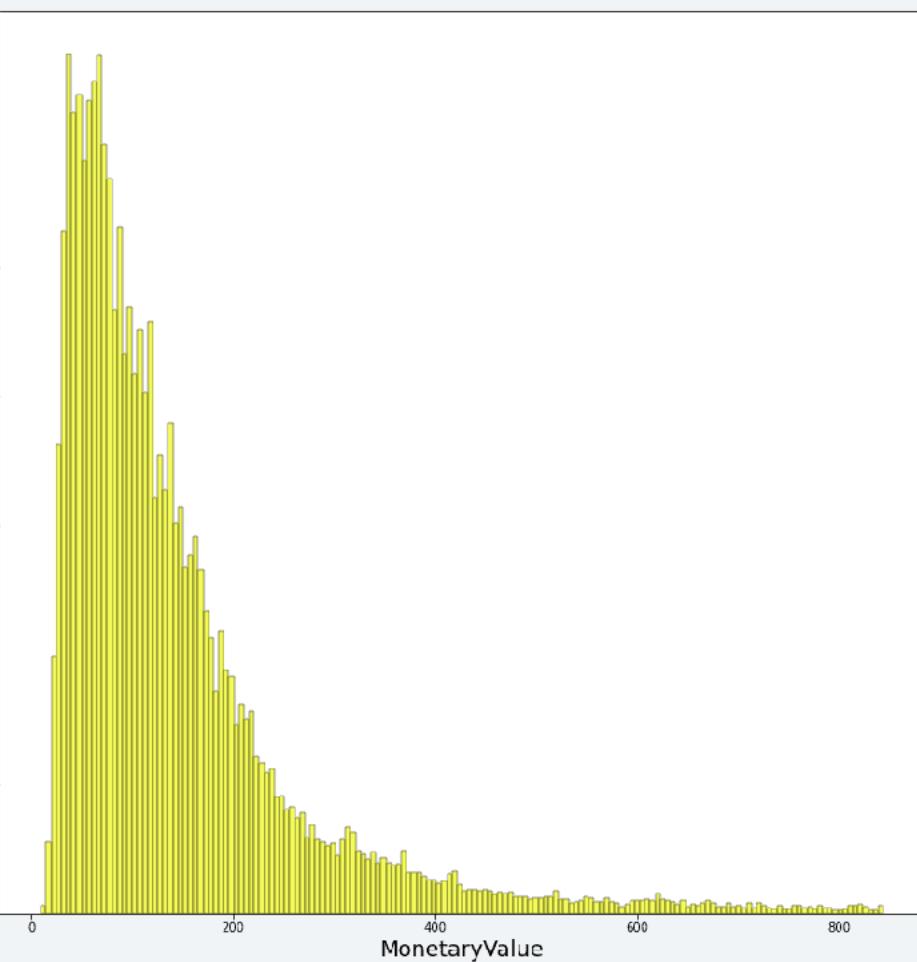
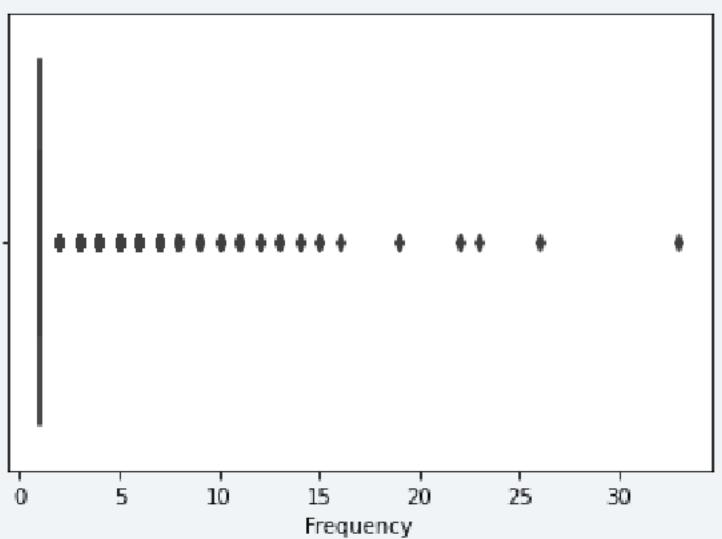


PO4_01_notebook_exploration.ipynb



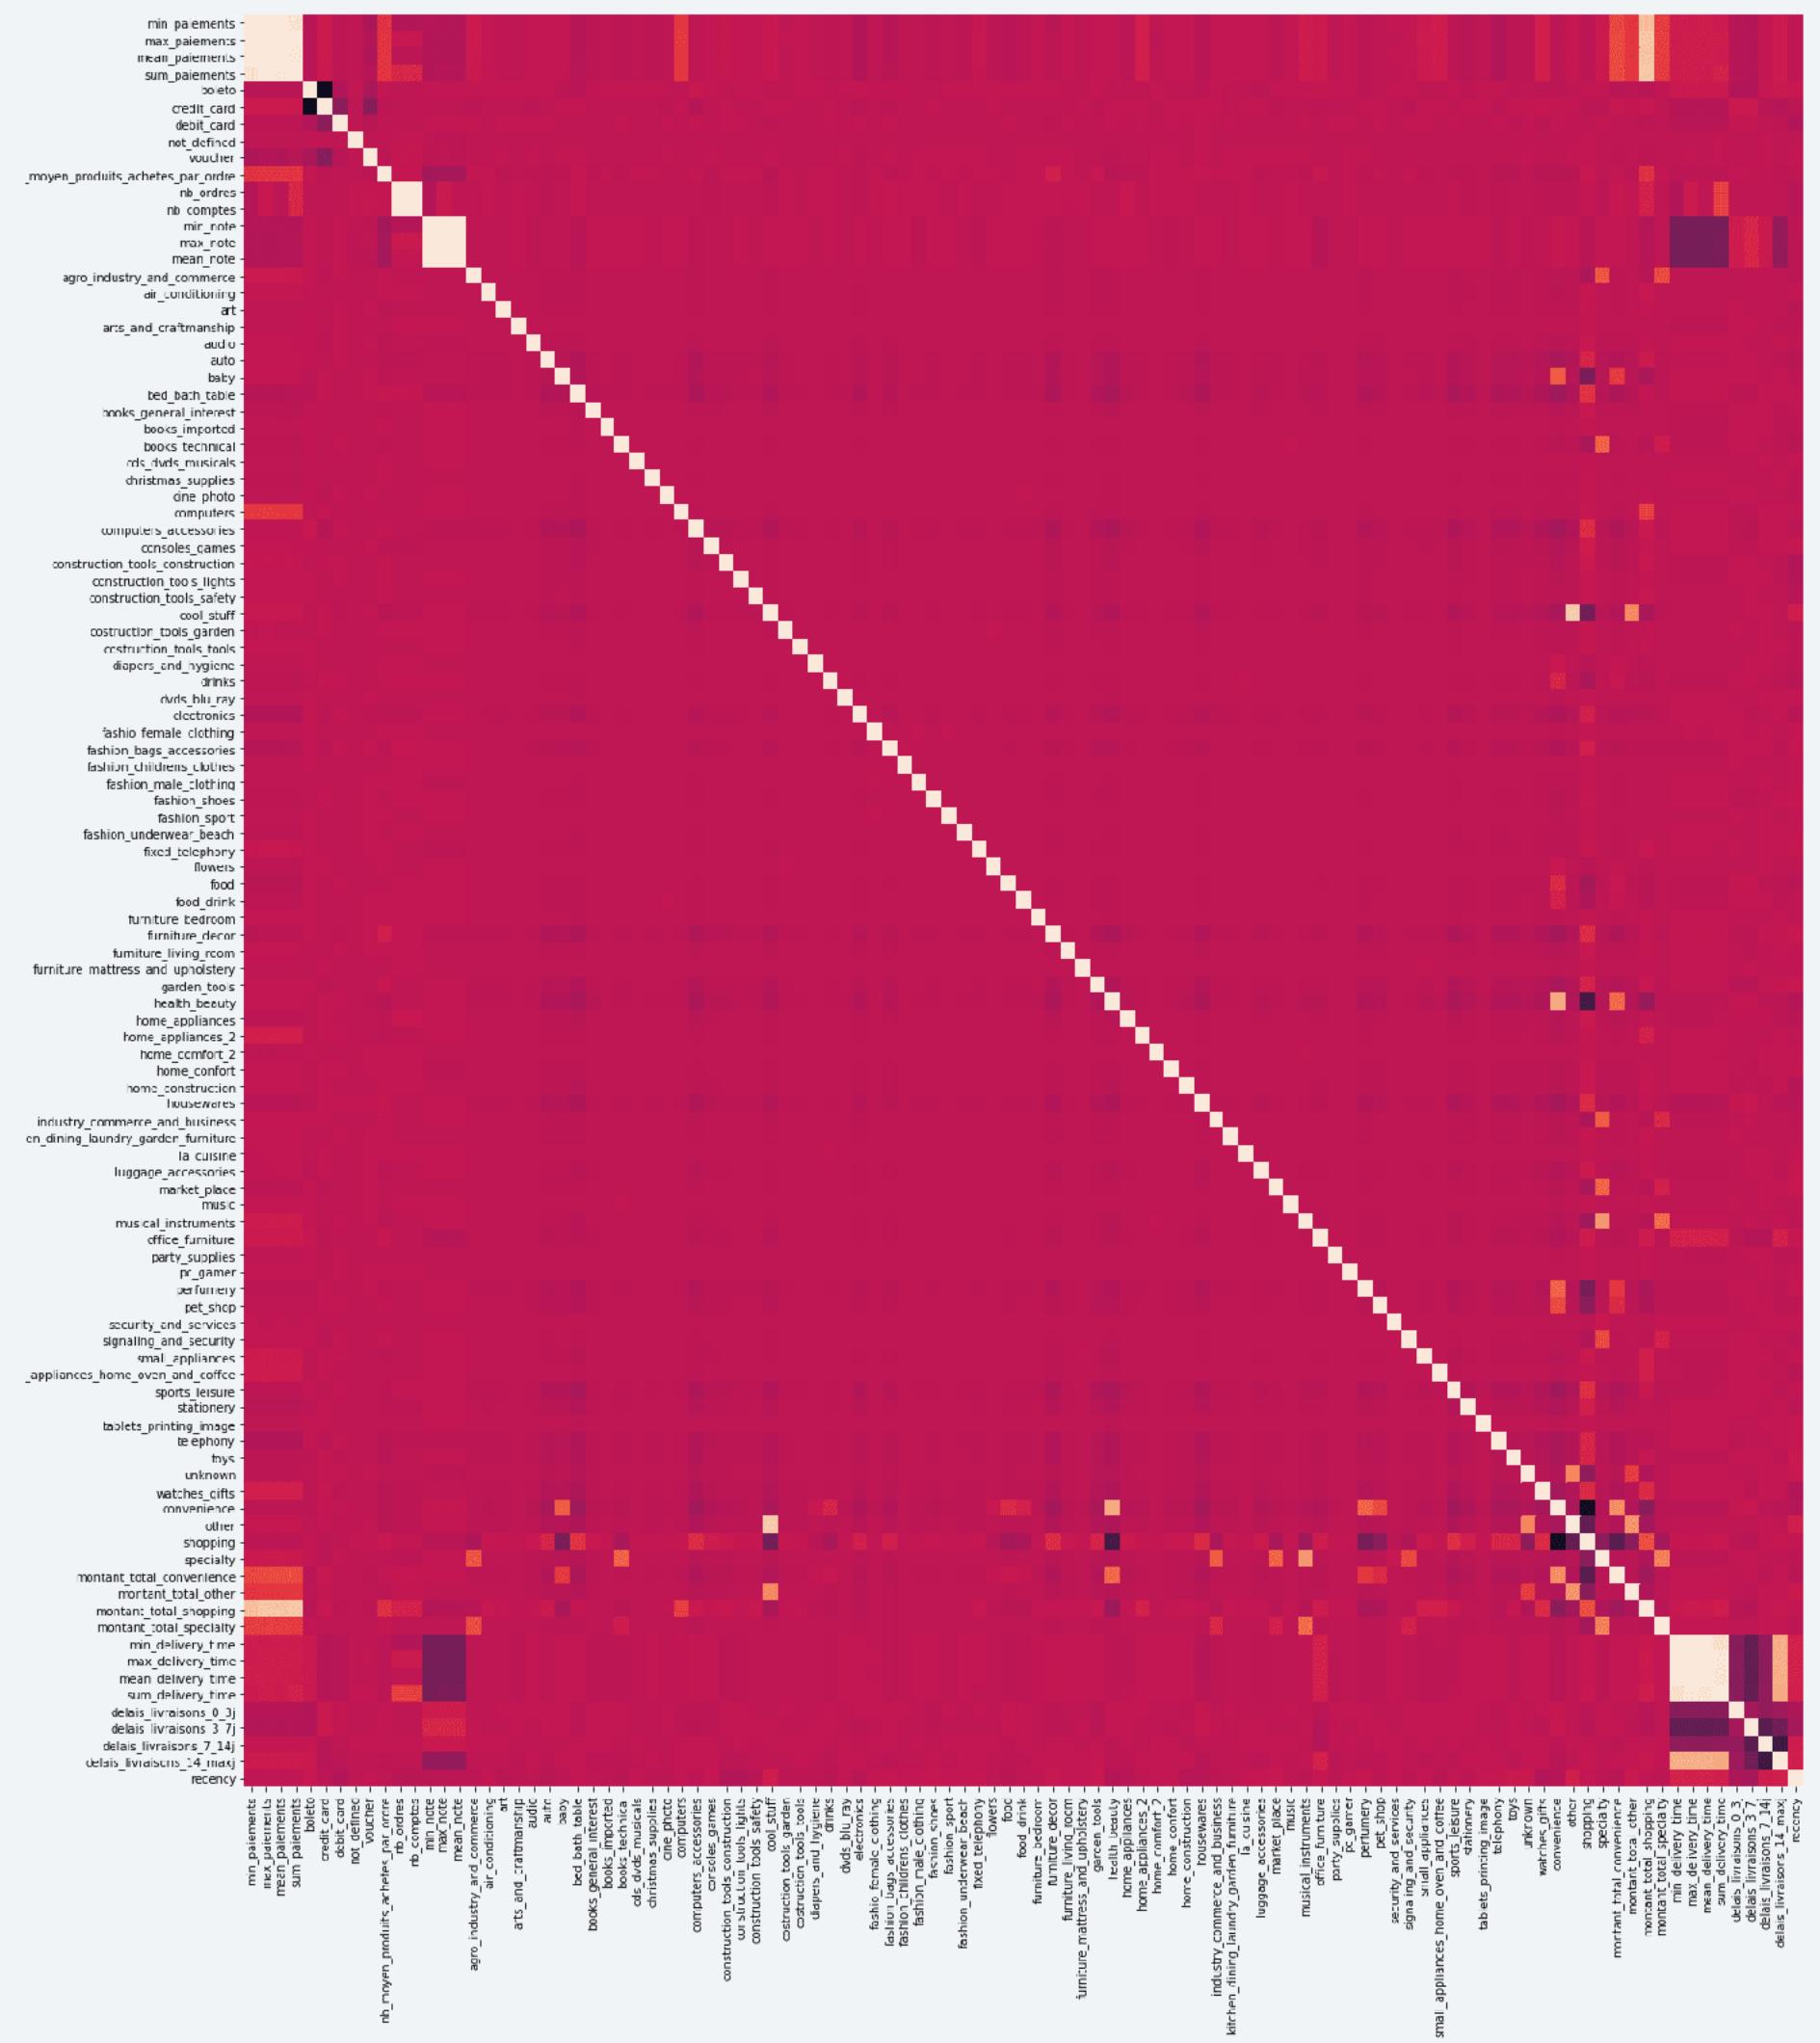
Observations :

- ! Le nombre d'ordres est en moyenne de 1.079, avec 94% des clients qui ne passent qu'un seul ordre, le jeu de données est-il biaisé ?



olist

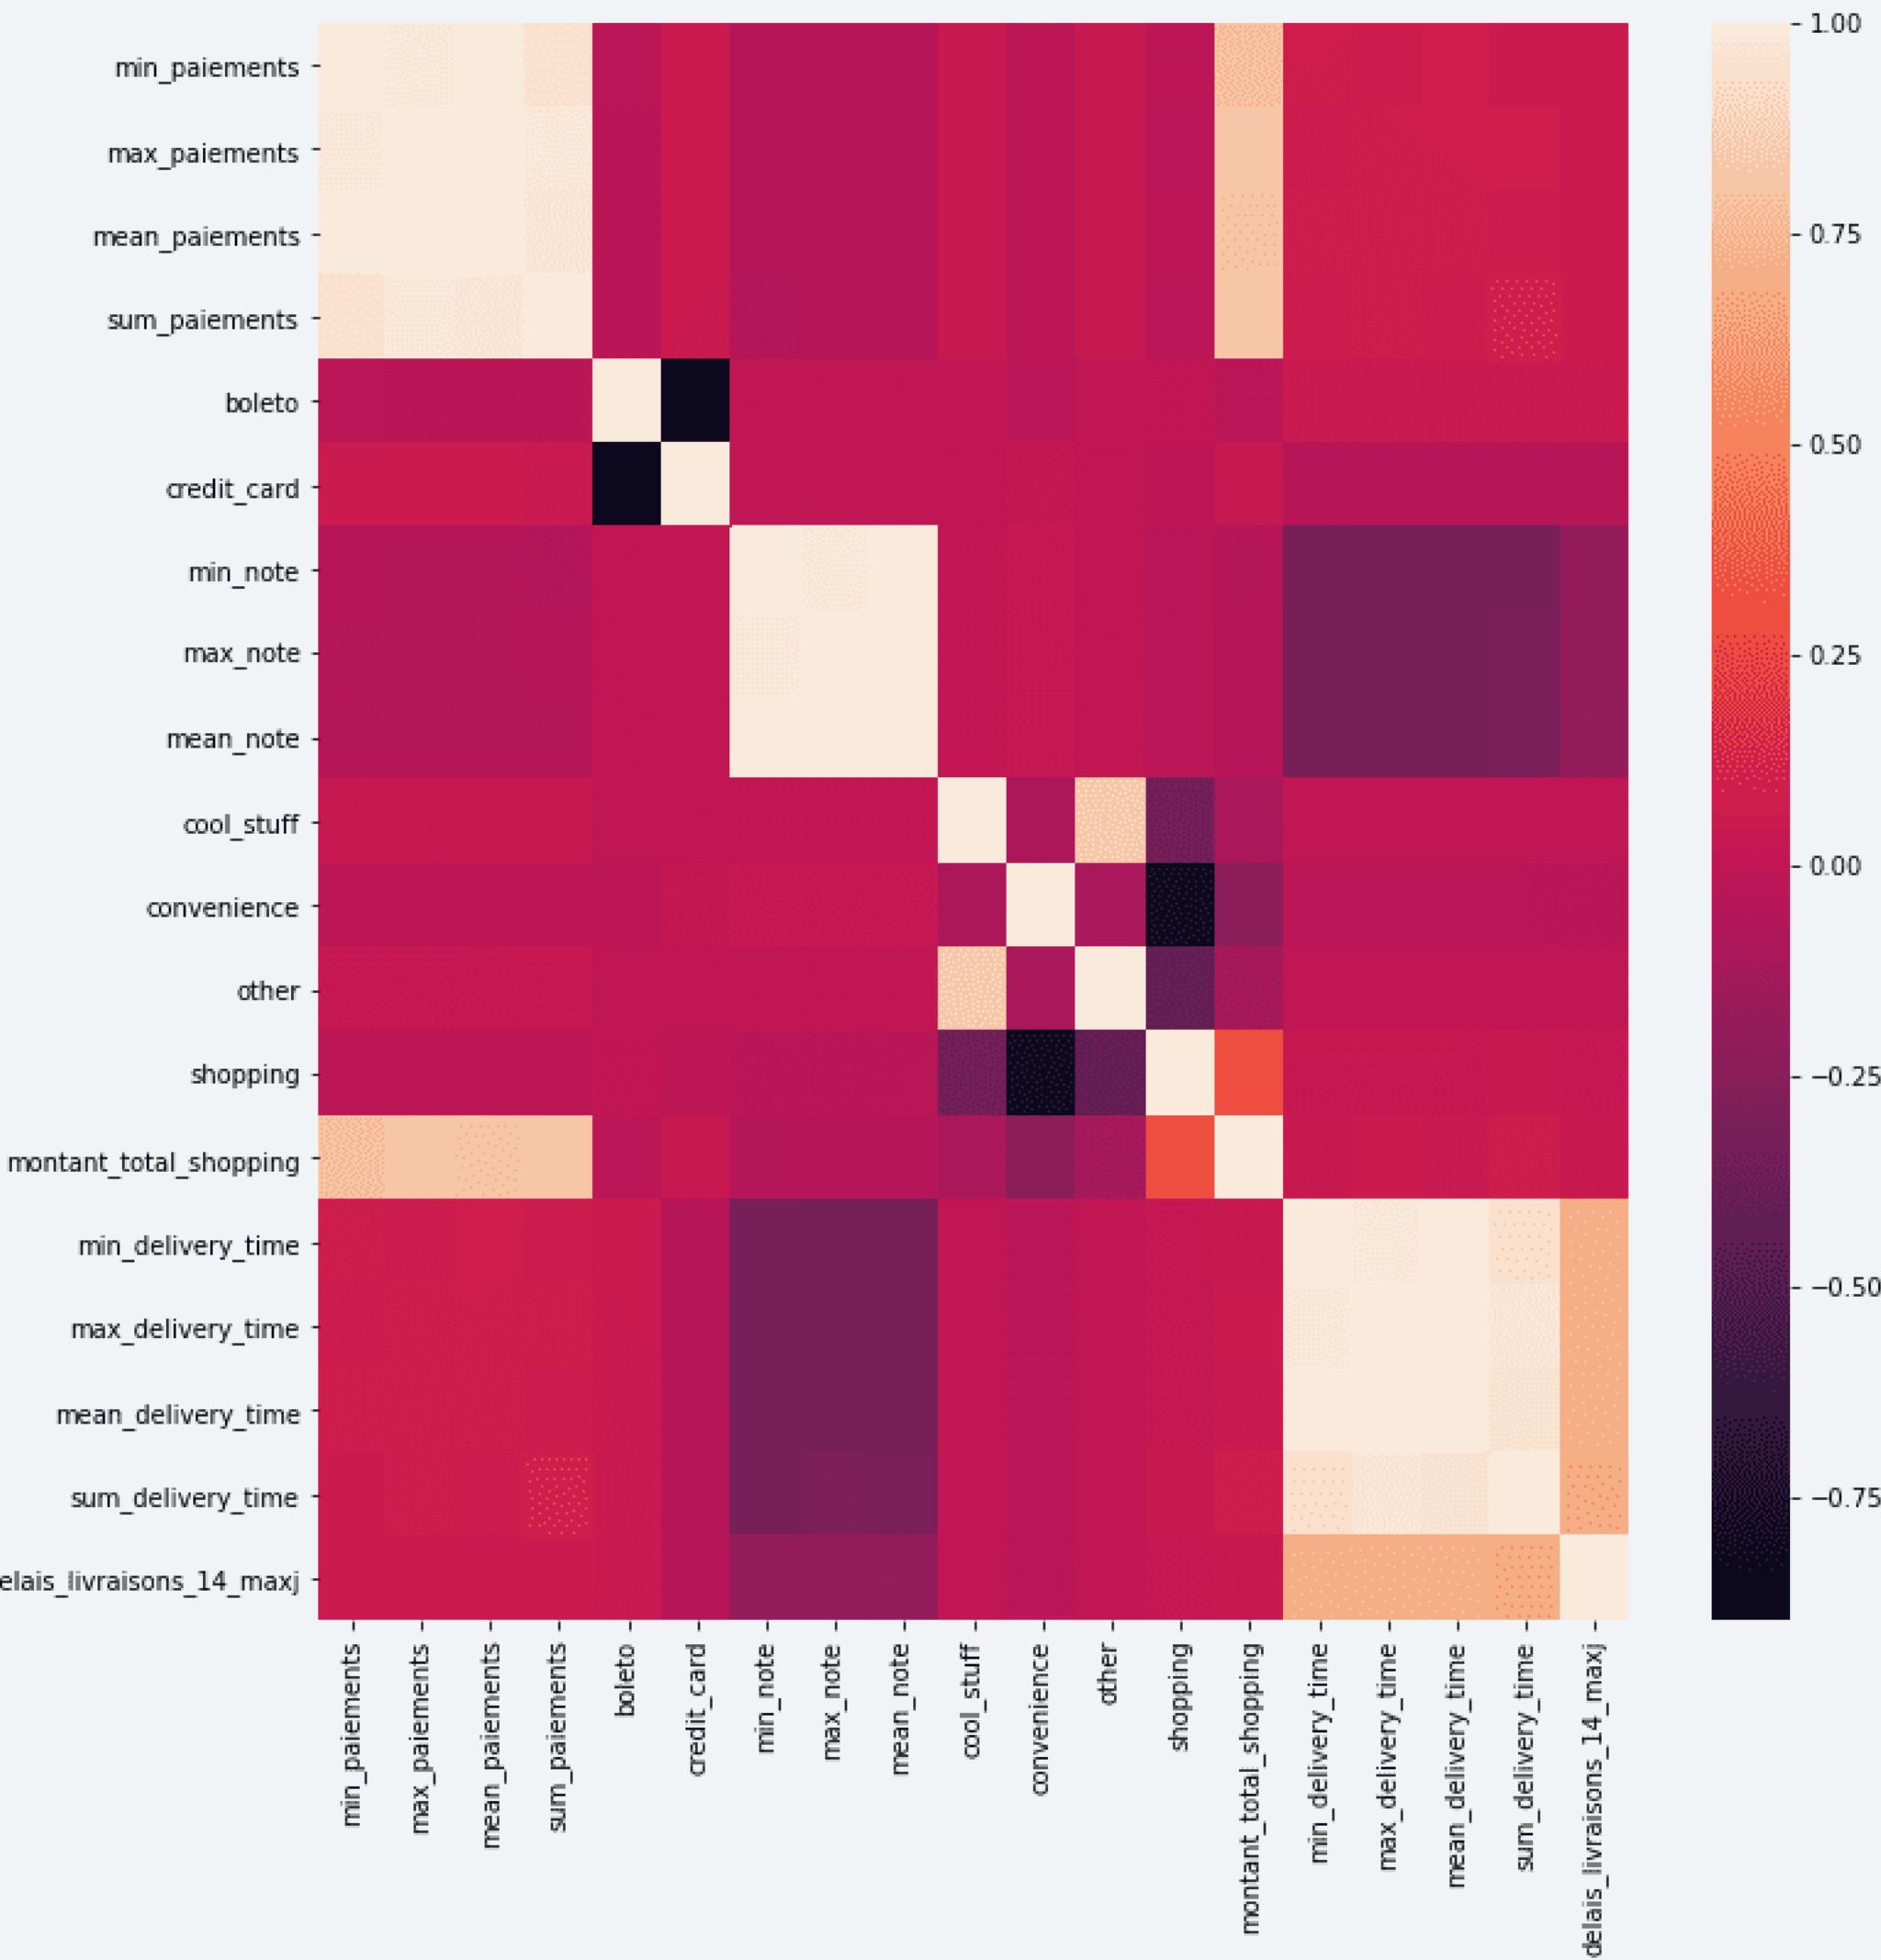
Matrice de corrélation sur $N=105$ dimensions



Matrice de corrélation réduite > (+)0.7



PO4_01_notebook_exploration.ipynb

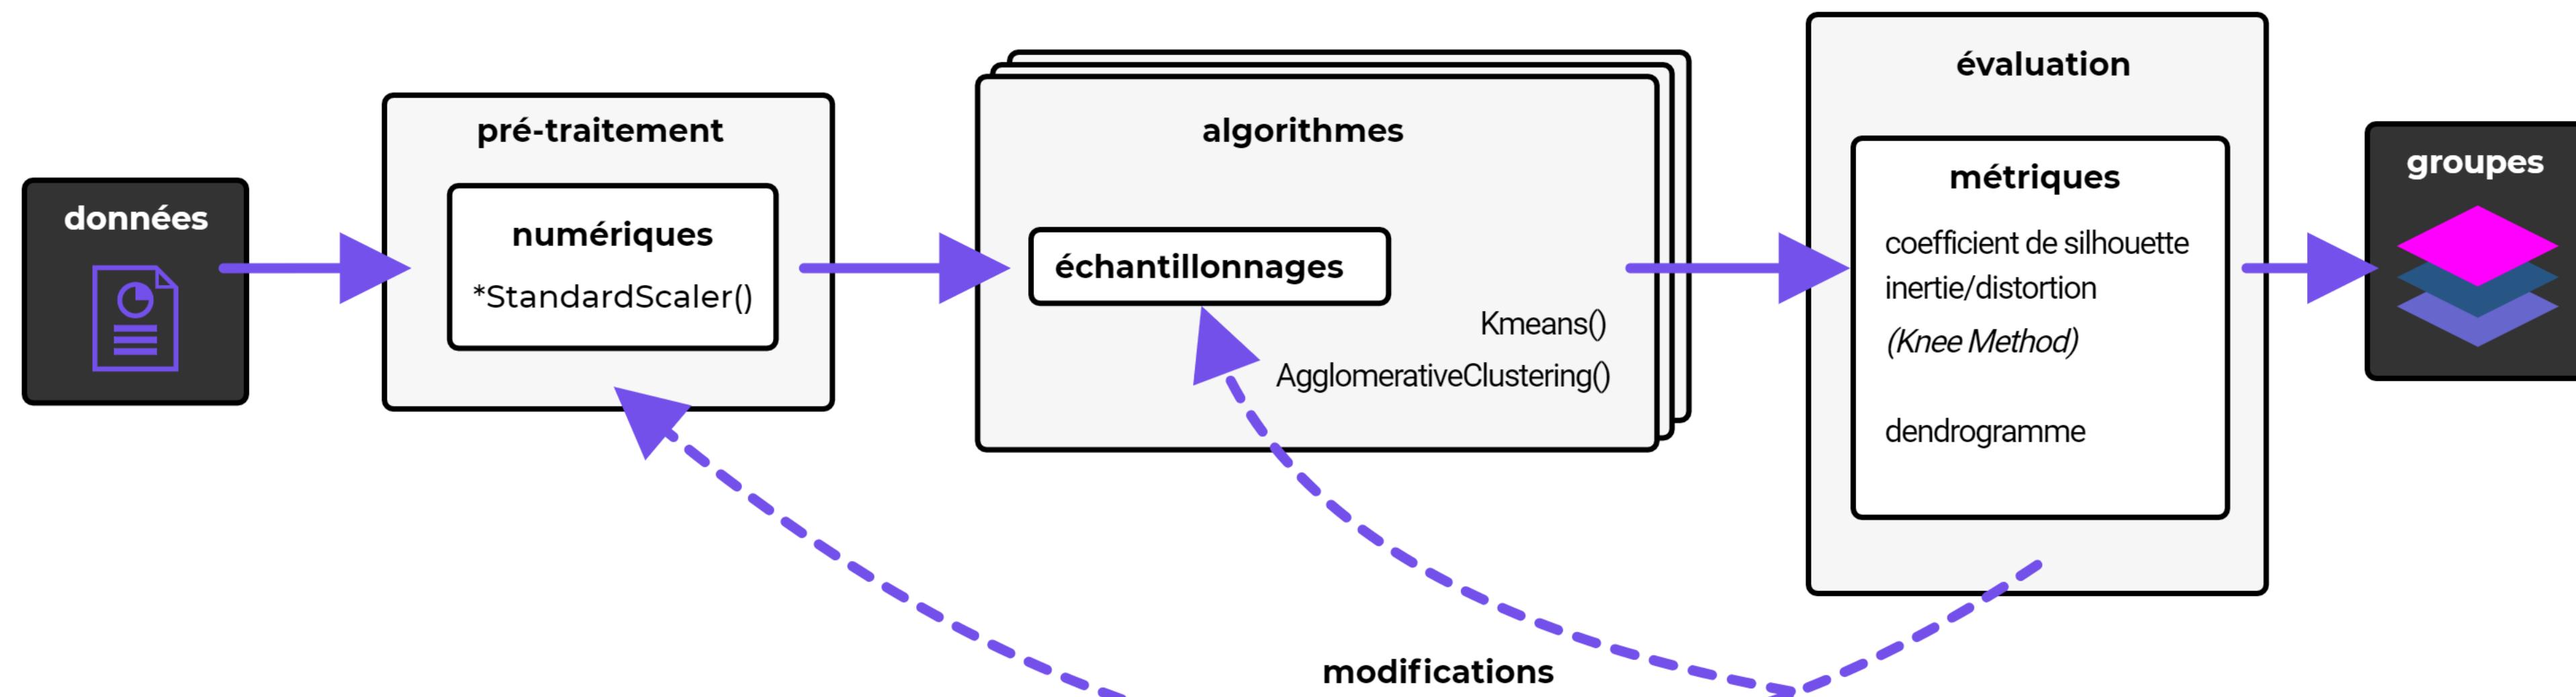


Corrélations :

- + Délais de livraisons / Notes
- + Montant total des produits achetés de type 'shopping' / Montant total paiements
- Paiement par billet / Paiement par CB



Process de classification non supervisée (dév)





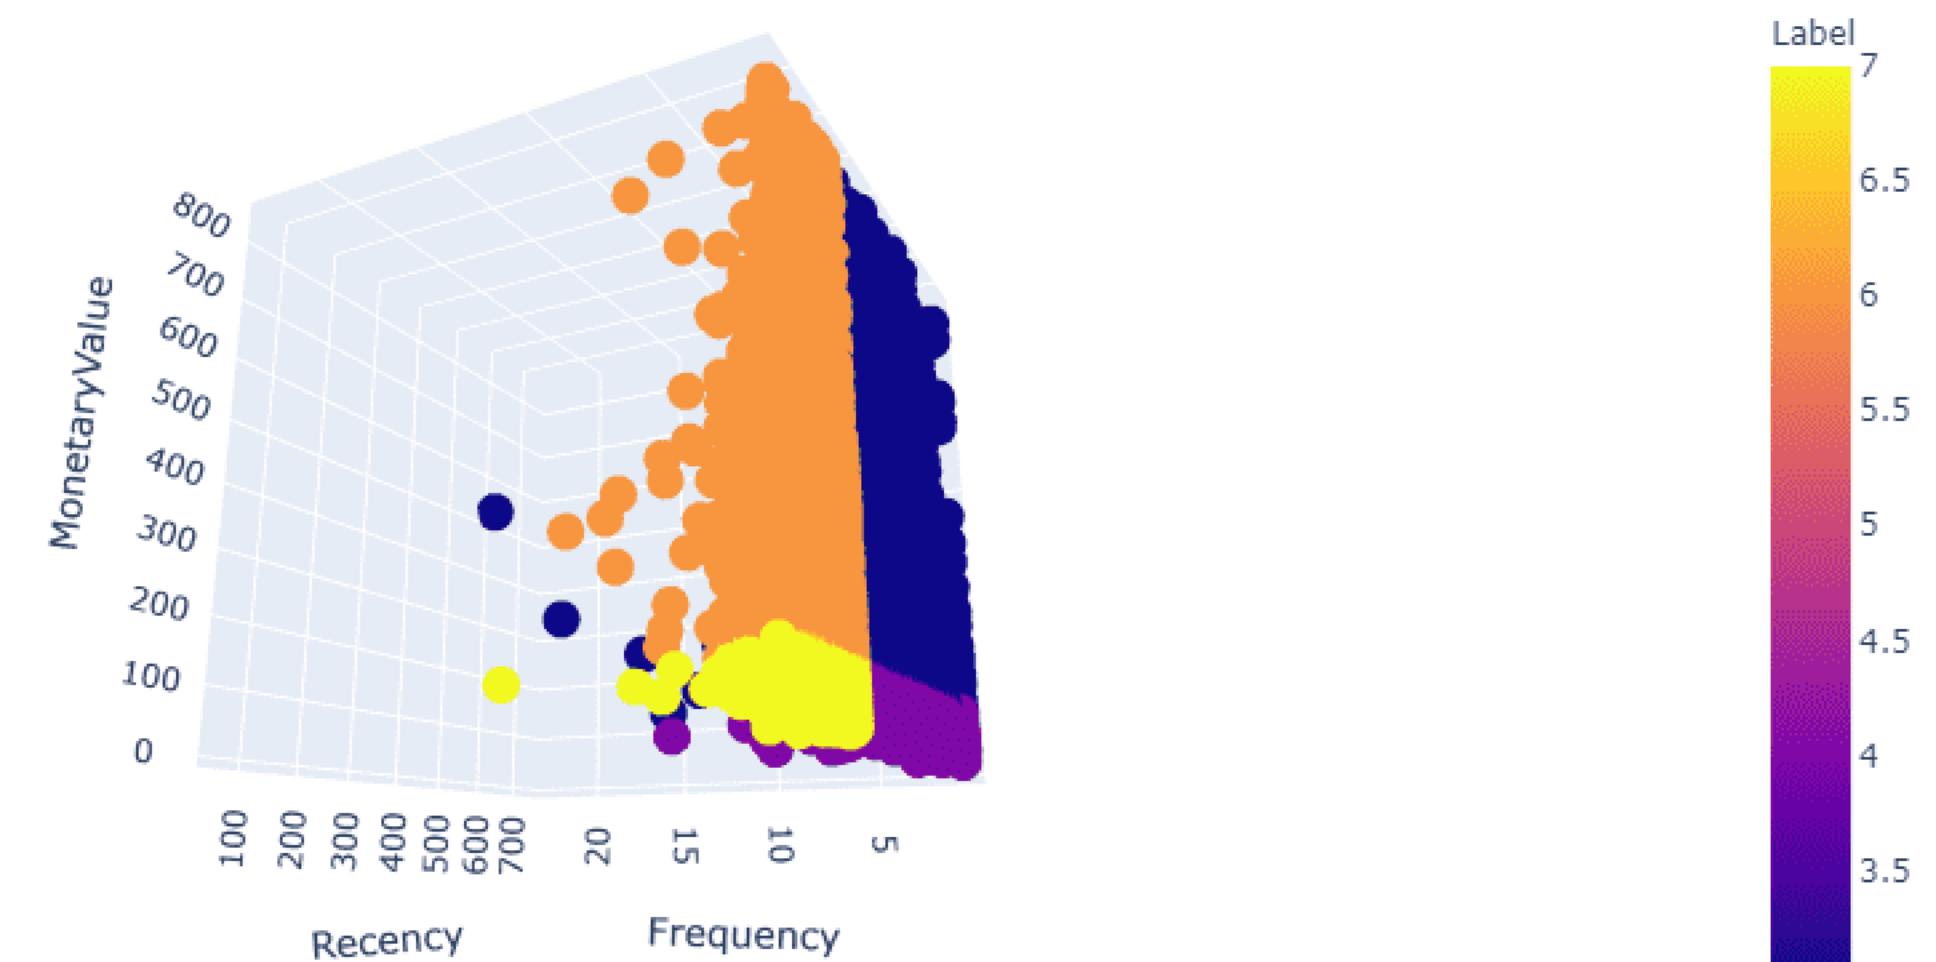
Segmentation sur N=3 dimensions RFM

Rules based Clustering

- sur un échantillon de 30%
- séparation en 8 classes arbitraires à priori

```
Entrée [7]: index_label_0 = df_rfmb.query('Recency < @level_recency and Frequency < @level_frequency and MonetaryValue < @level_monetaryValue')
index_label_1 = df_rfmb.query('Recency < @level_recency and Frequency < @level_frequency and MonetaryValue >= @level_monetaryValue')
index_label_2 = df_rfmb.query('Recency >= @level_recency and Frequency < @level_frequency and MonetaryValue < @level_monetaryValue')
index_label_3 = df_rfmb.query('Recency >= @level_recency and Frequency >= @level_frequency and MonetaryValue >= @level_monetaryValue')
index_label_4 = df_rfmb.query('Recency >= @level_recency and Frequency >= @level_frequency and MonetaryValue < @level_monetaryValue')
index_label_5 = df_rfmb.query('Recency >= @level_recency and Frequency < @level_frequency and MonetaryValue >= @level_monetaryValue')
index_label_6 = df_rfmb.query('Recency < @level_recency and Frequency >= @level_frequency and MonetaryValue >= @level_monetaryValue')
index_label_7 = df_rfmb.query('Recency < @level_recency and Frequency >= @level_frequency and MonetaryValue < @level_monetaryValue')

Entrée [8]: #Séparation en 8 classes arbitraires
df_rfmb.loc[index_label_0, ['Label']] = 0
df_rfmb.loc[index_label_1, ['Label']] = 1
df_rfmb.loc[index_label_2, ['Label']] = 2
df_rfmb.loc[index_label_3, ['Label']] = 3
df_rfmb.loc[index_label_4, ['Label']] = 4
df_rfmb.loc[index_label_5, ['Label']] = 5
df_rfmb.loc[index_label_6, ['Label']] = 6
df_rfmb.loc[index_label_7, ['Label']] = 7
```

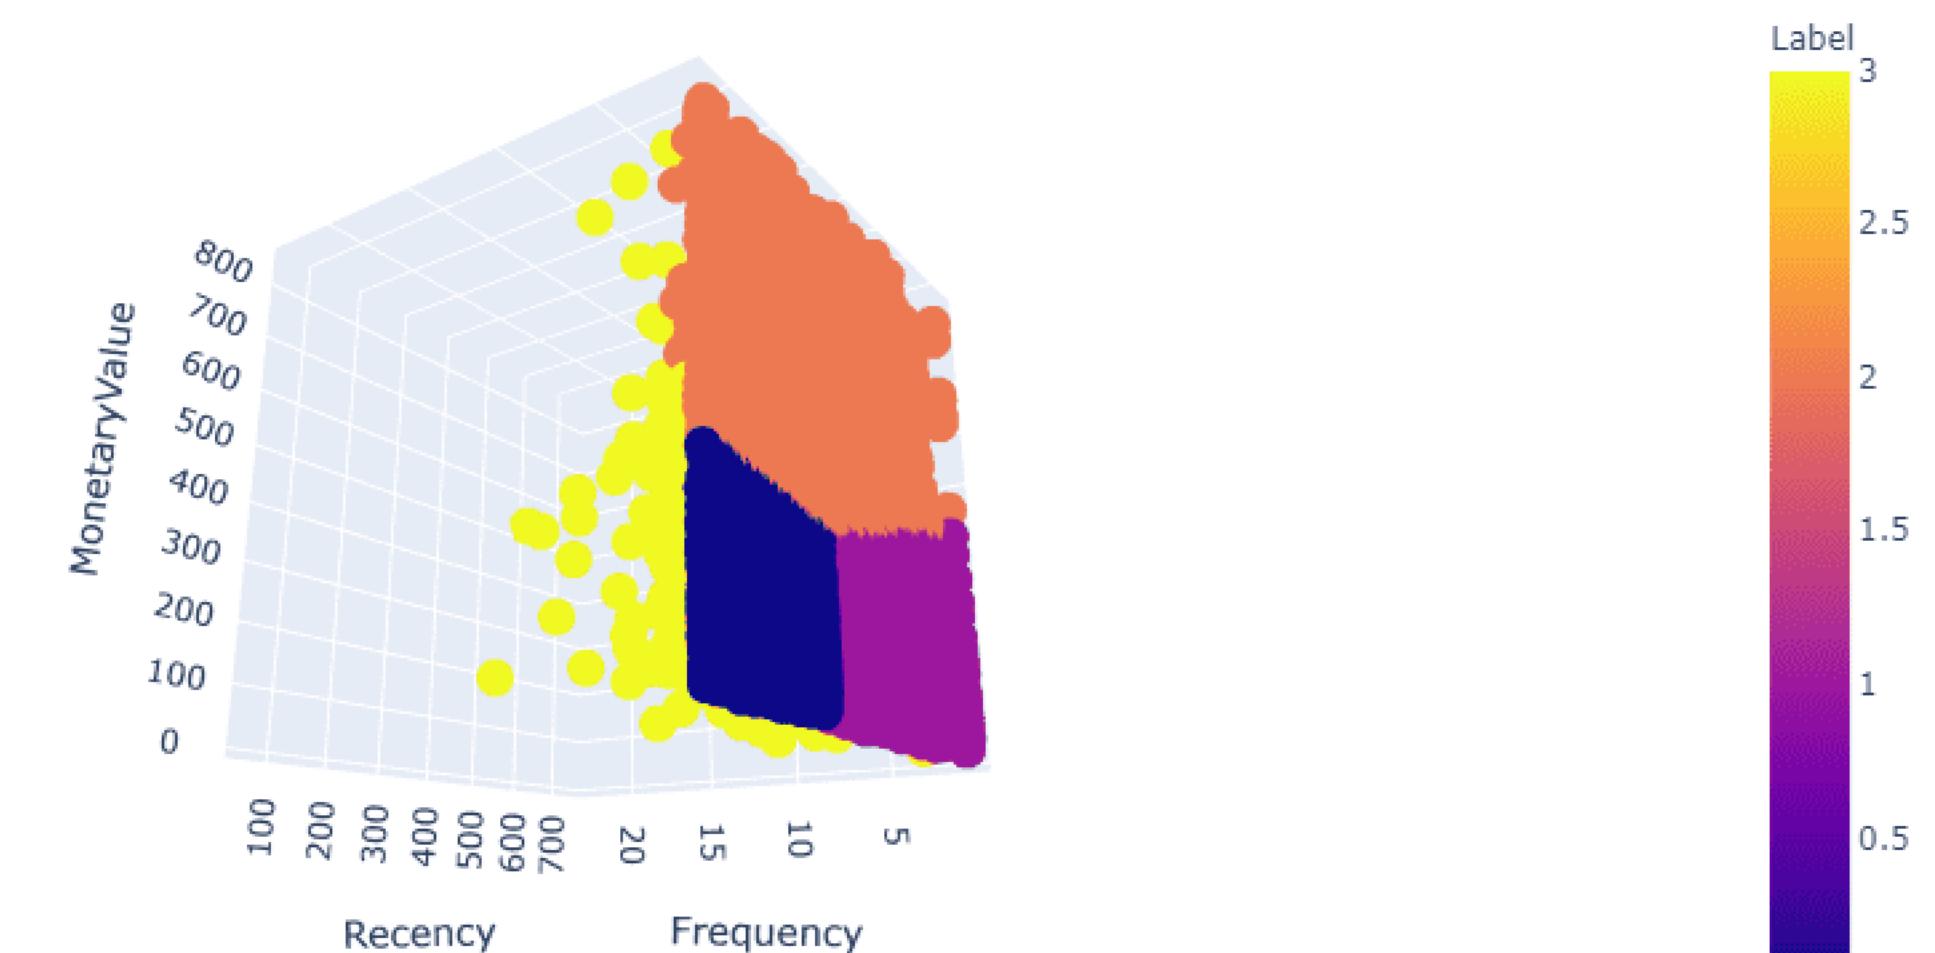
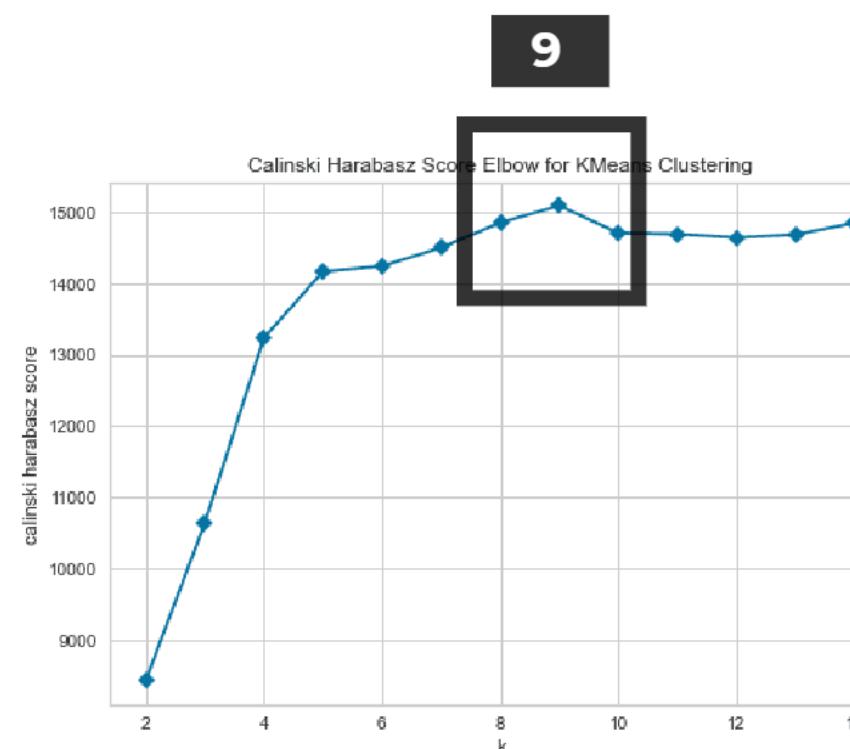
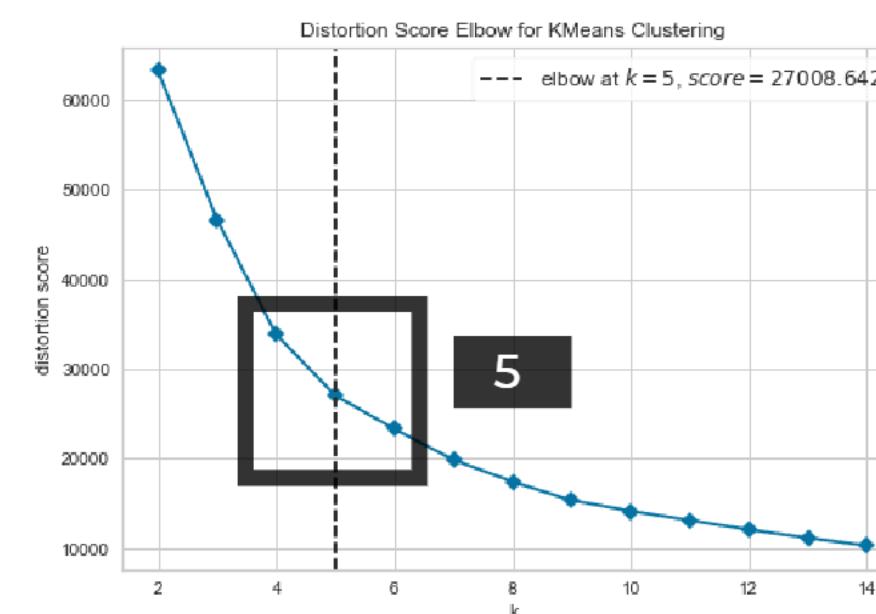




Segmentation sur $N=3$ dimensions RFM

Kmeans Clustering

- (K= 2 to 15)
- sur un échantillon de 30%
- métriques divergentes - essai sur separation en 4 classes à posteriori





Segmentation sur **N=3** dimensions RFM

On peut visuellement constater l'absence de clusters bien séparés.



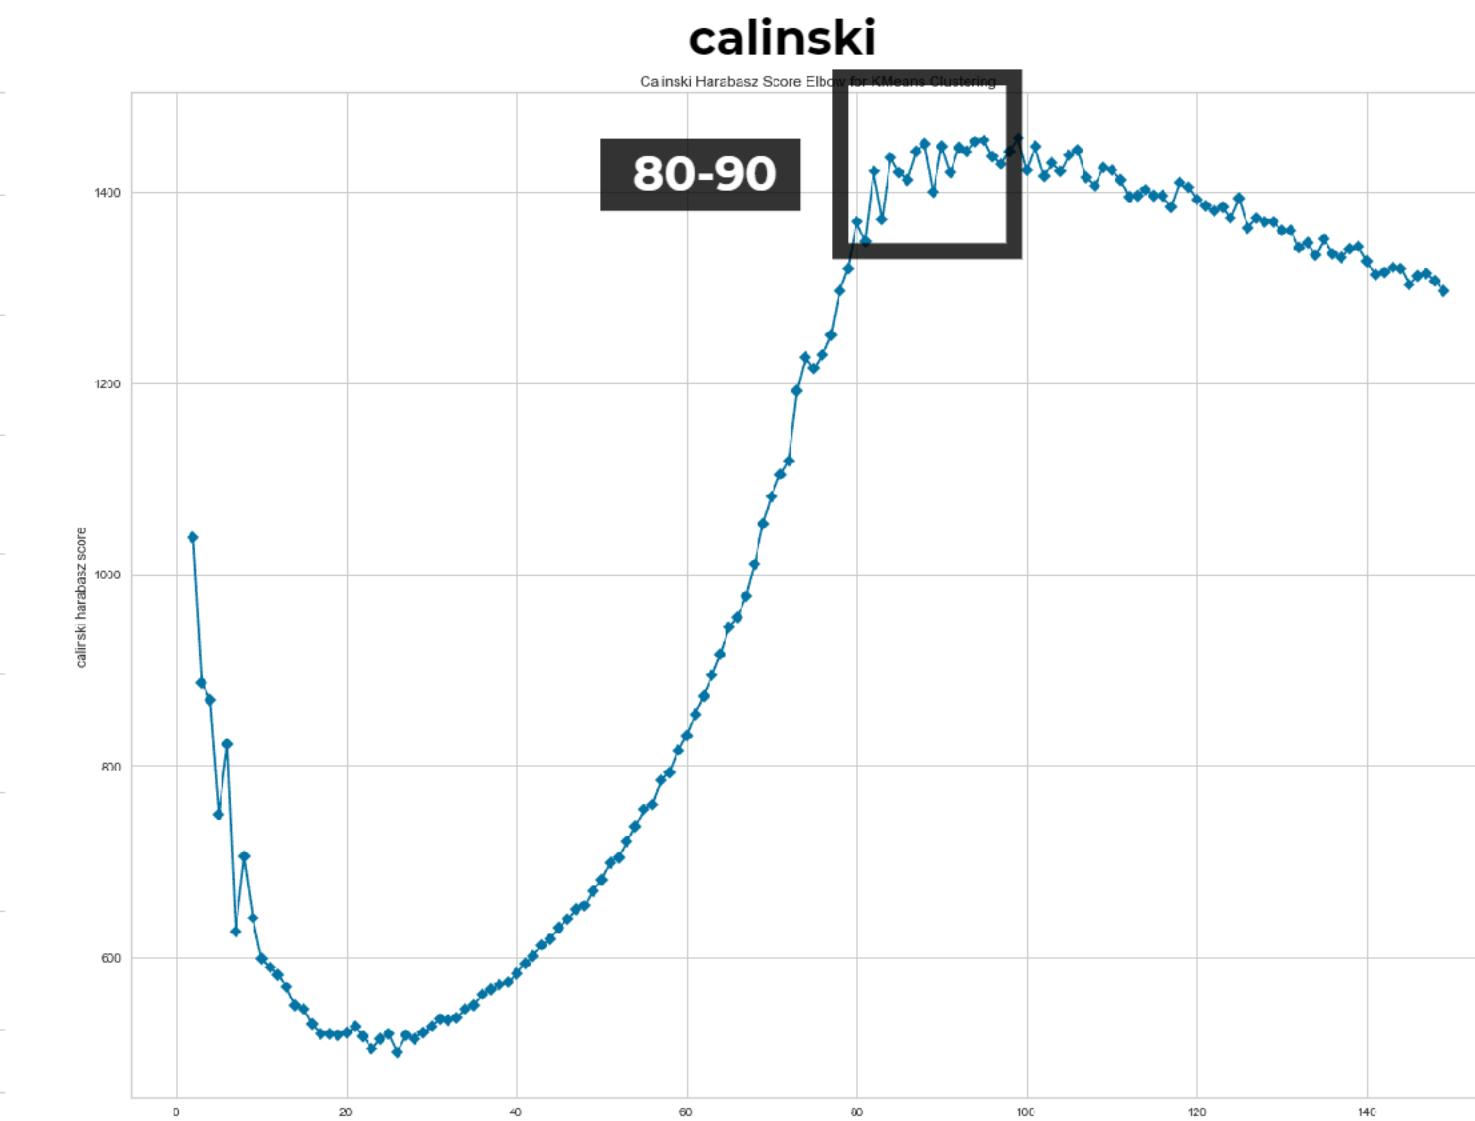
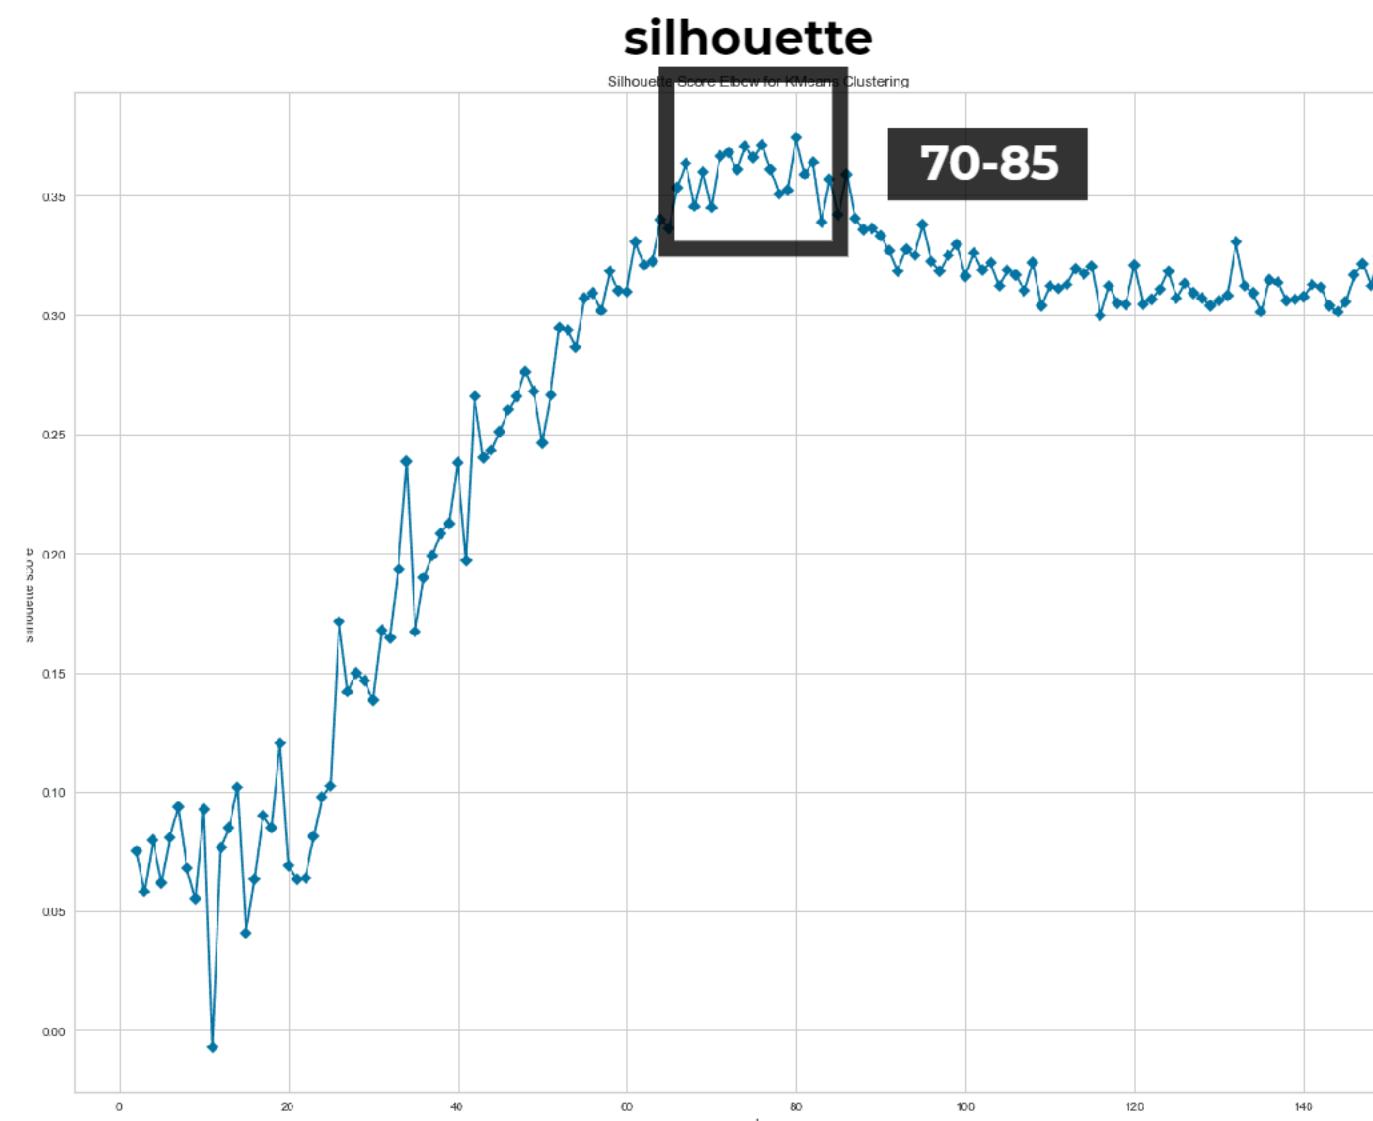
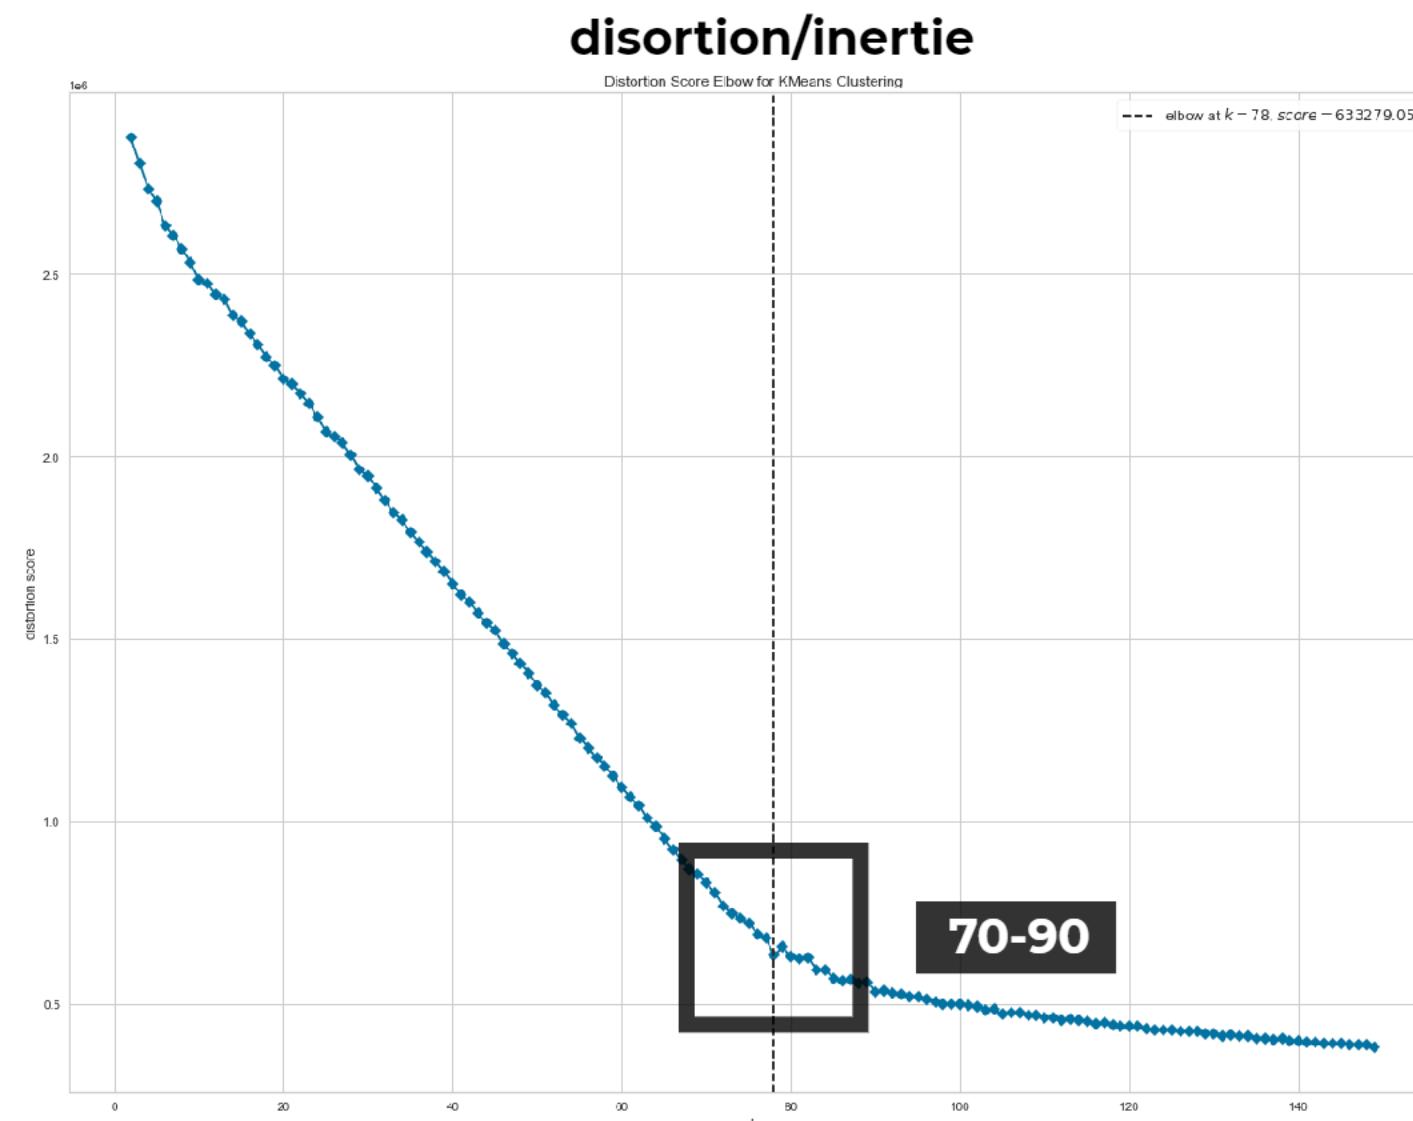
D'un point de vue marketing, une segmentation arbitraire peut cependant être utile si l'on veut cibler une partie de l'ensemble des clients.



Segmentation sur $N=105$ dimensions

Kmeans Clustering

- **K= 2 à 150**
- sur un échantillon de **30%**
- métriques convergentes pour une séparation de 75 à 90 classes

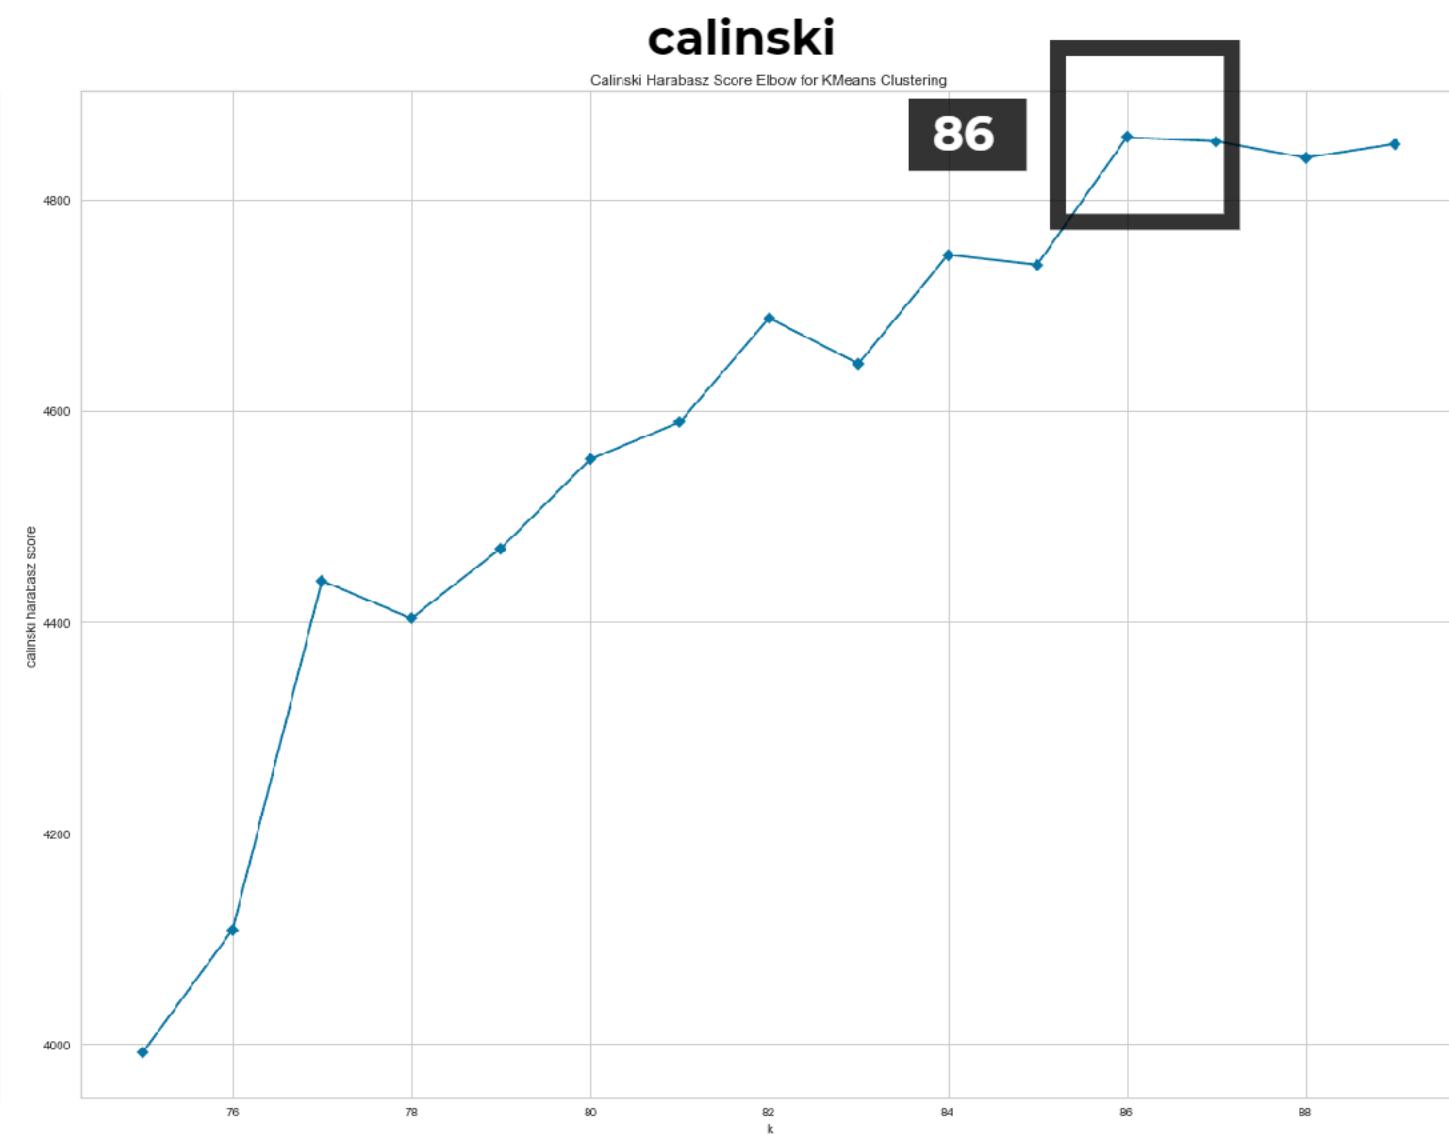
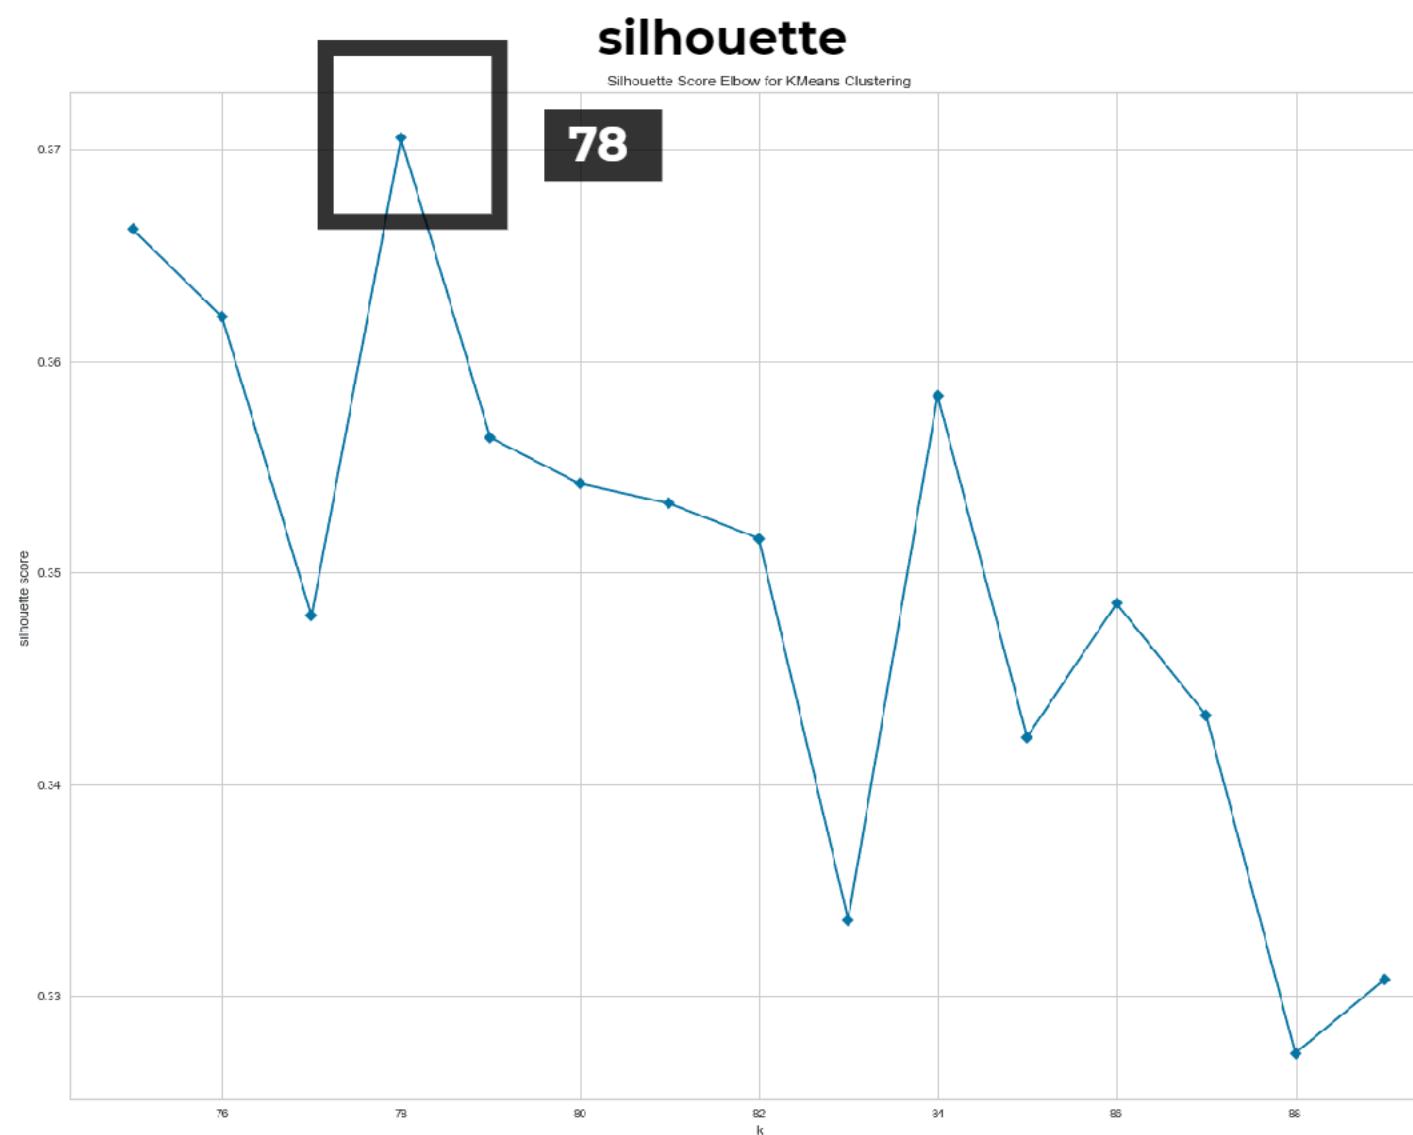
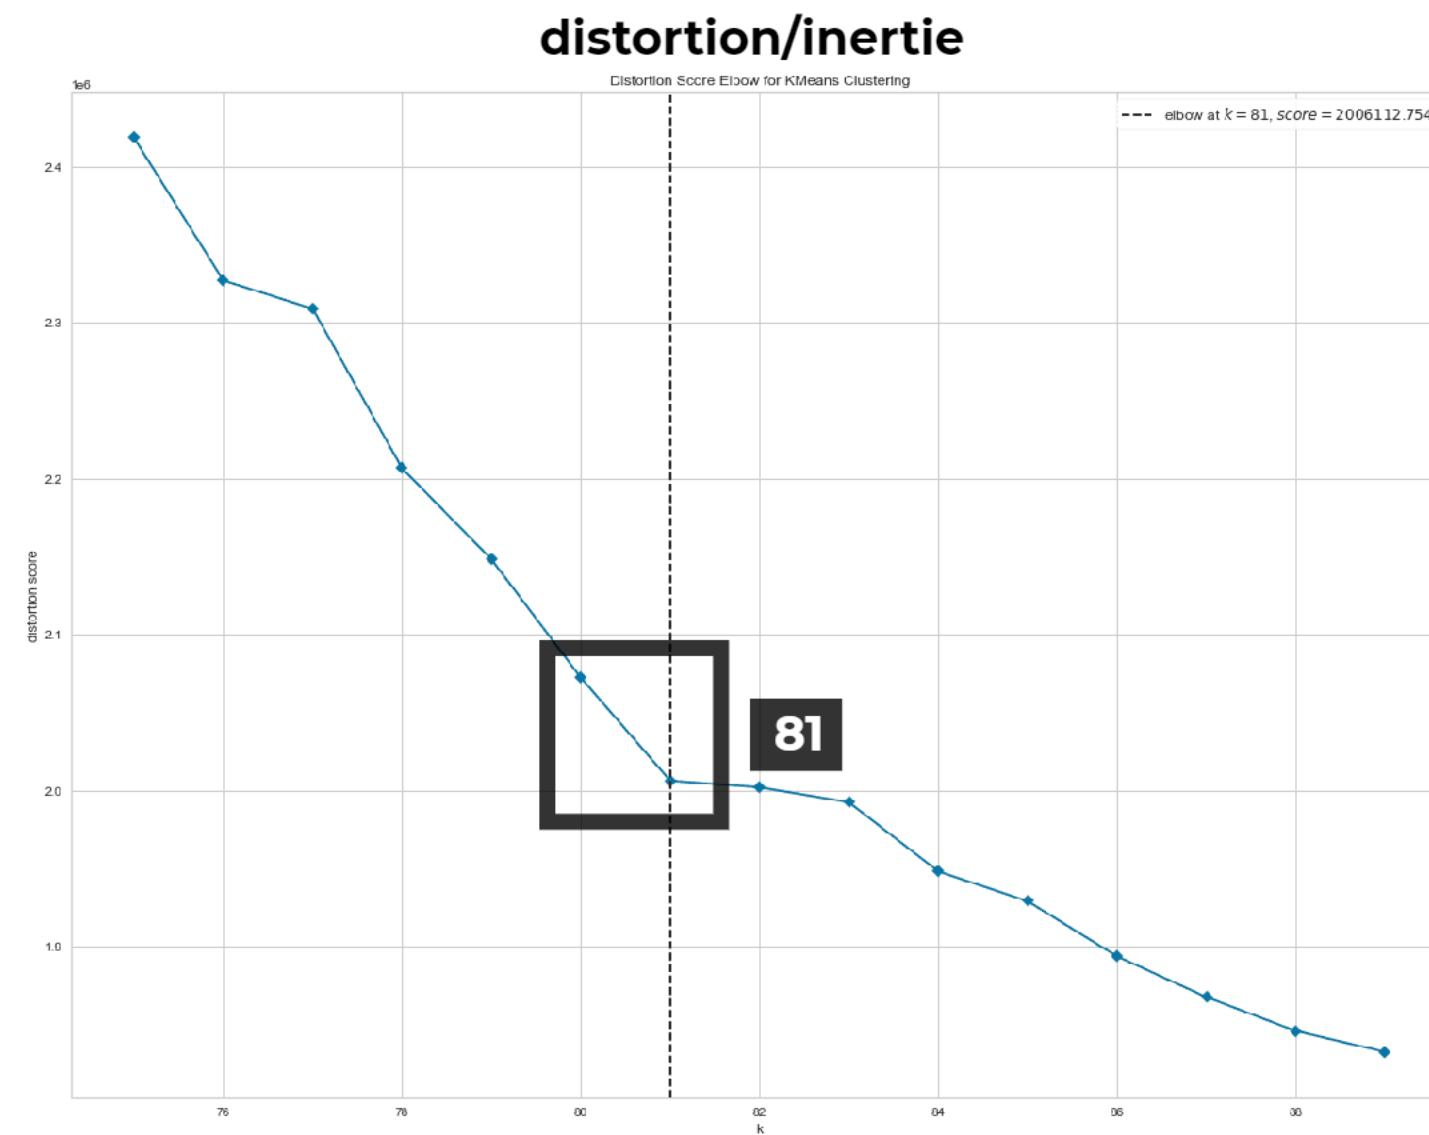




Segmentation sur $N=105$ dimensions

Kmeans Clustering

- **K= 75 à 90**
- sur **100%**
- métriques convergentes pour une séparation de 78 à 86 classes



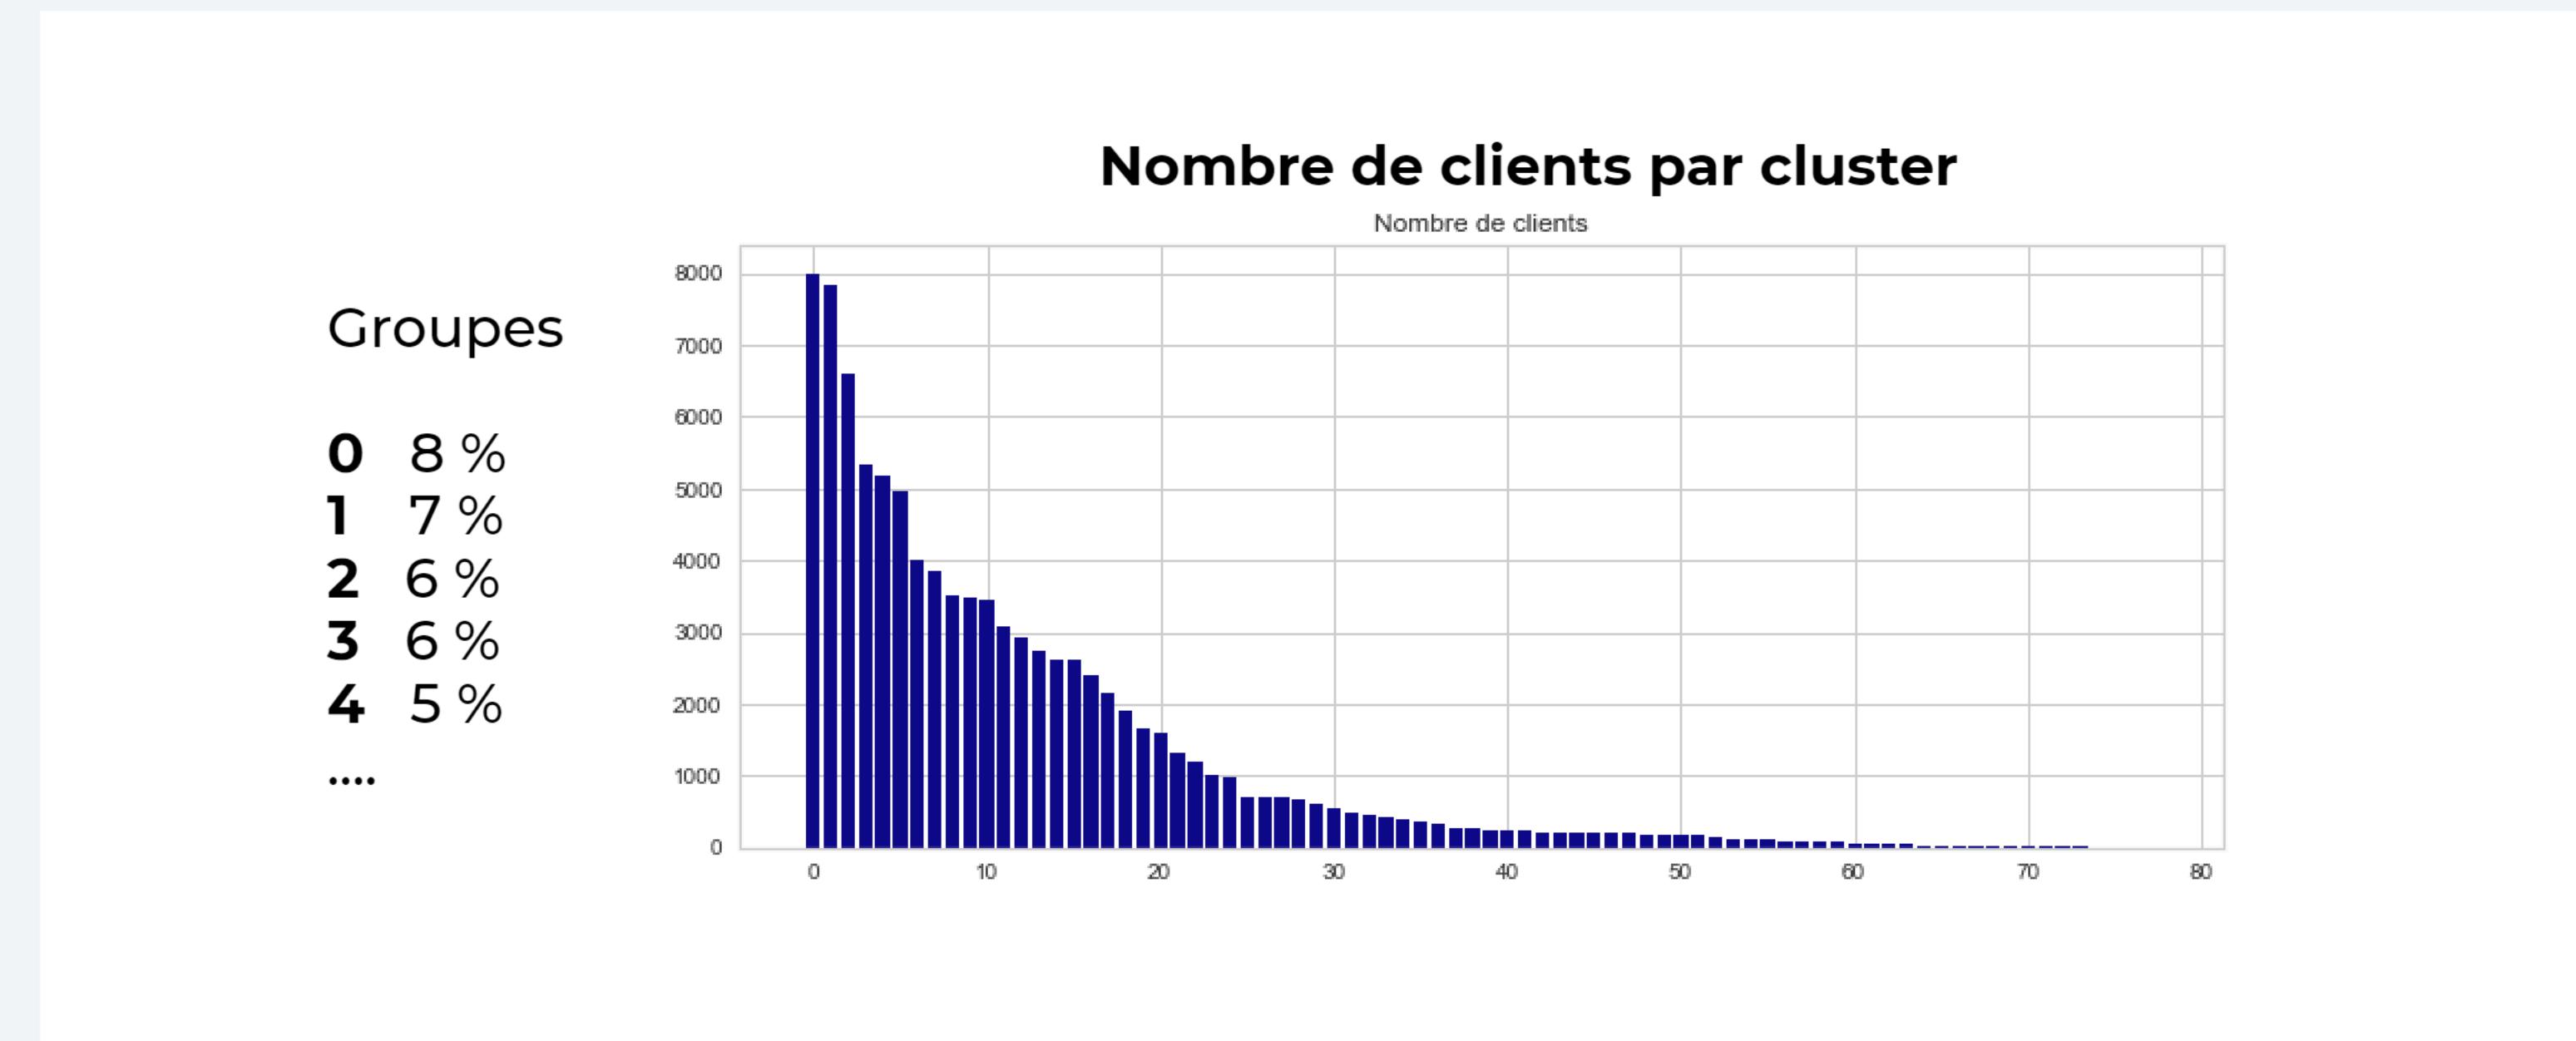


algorithme sélectionné
KMeans()

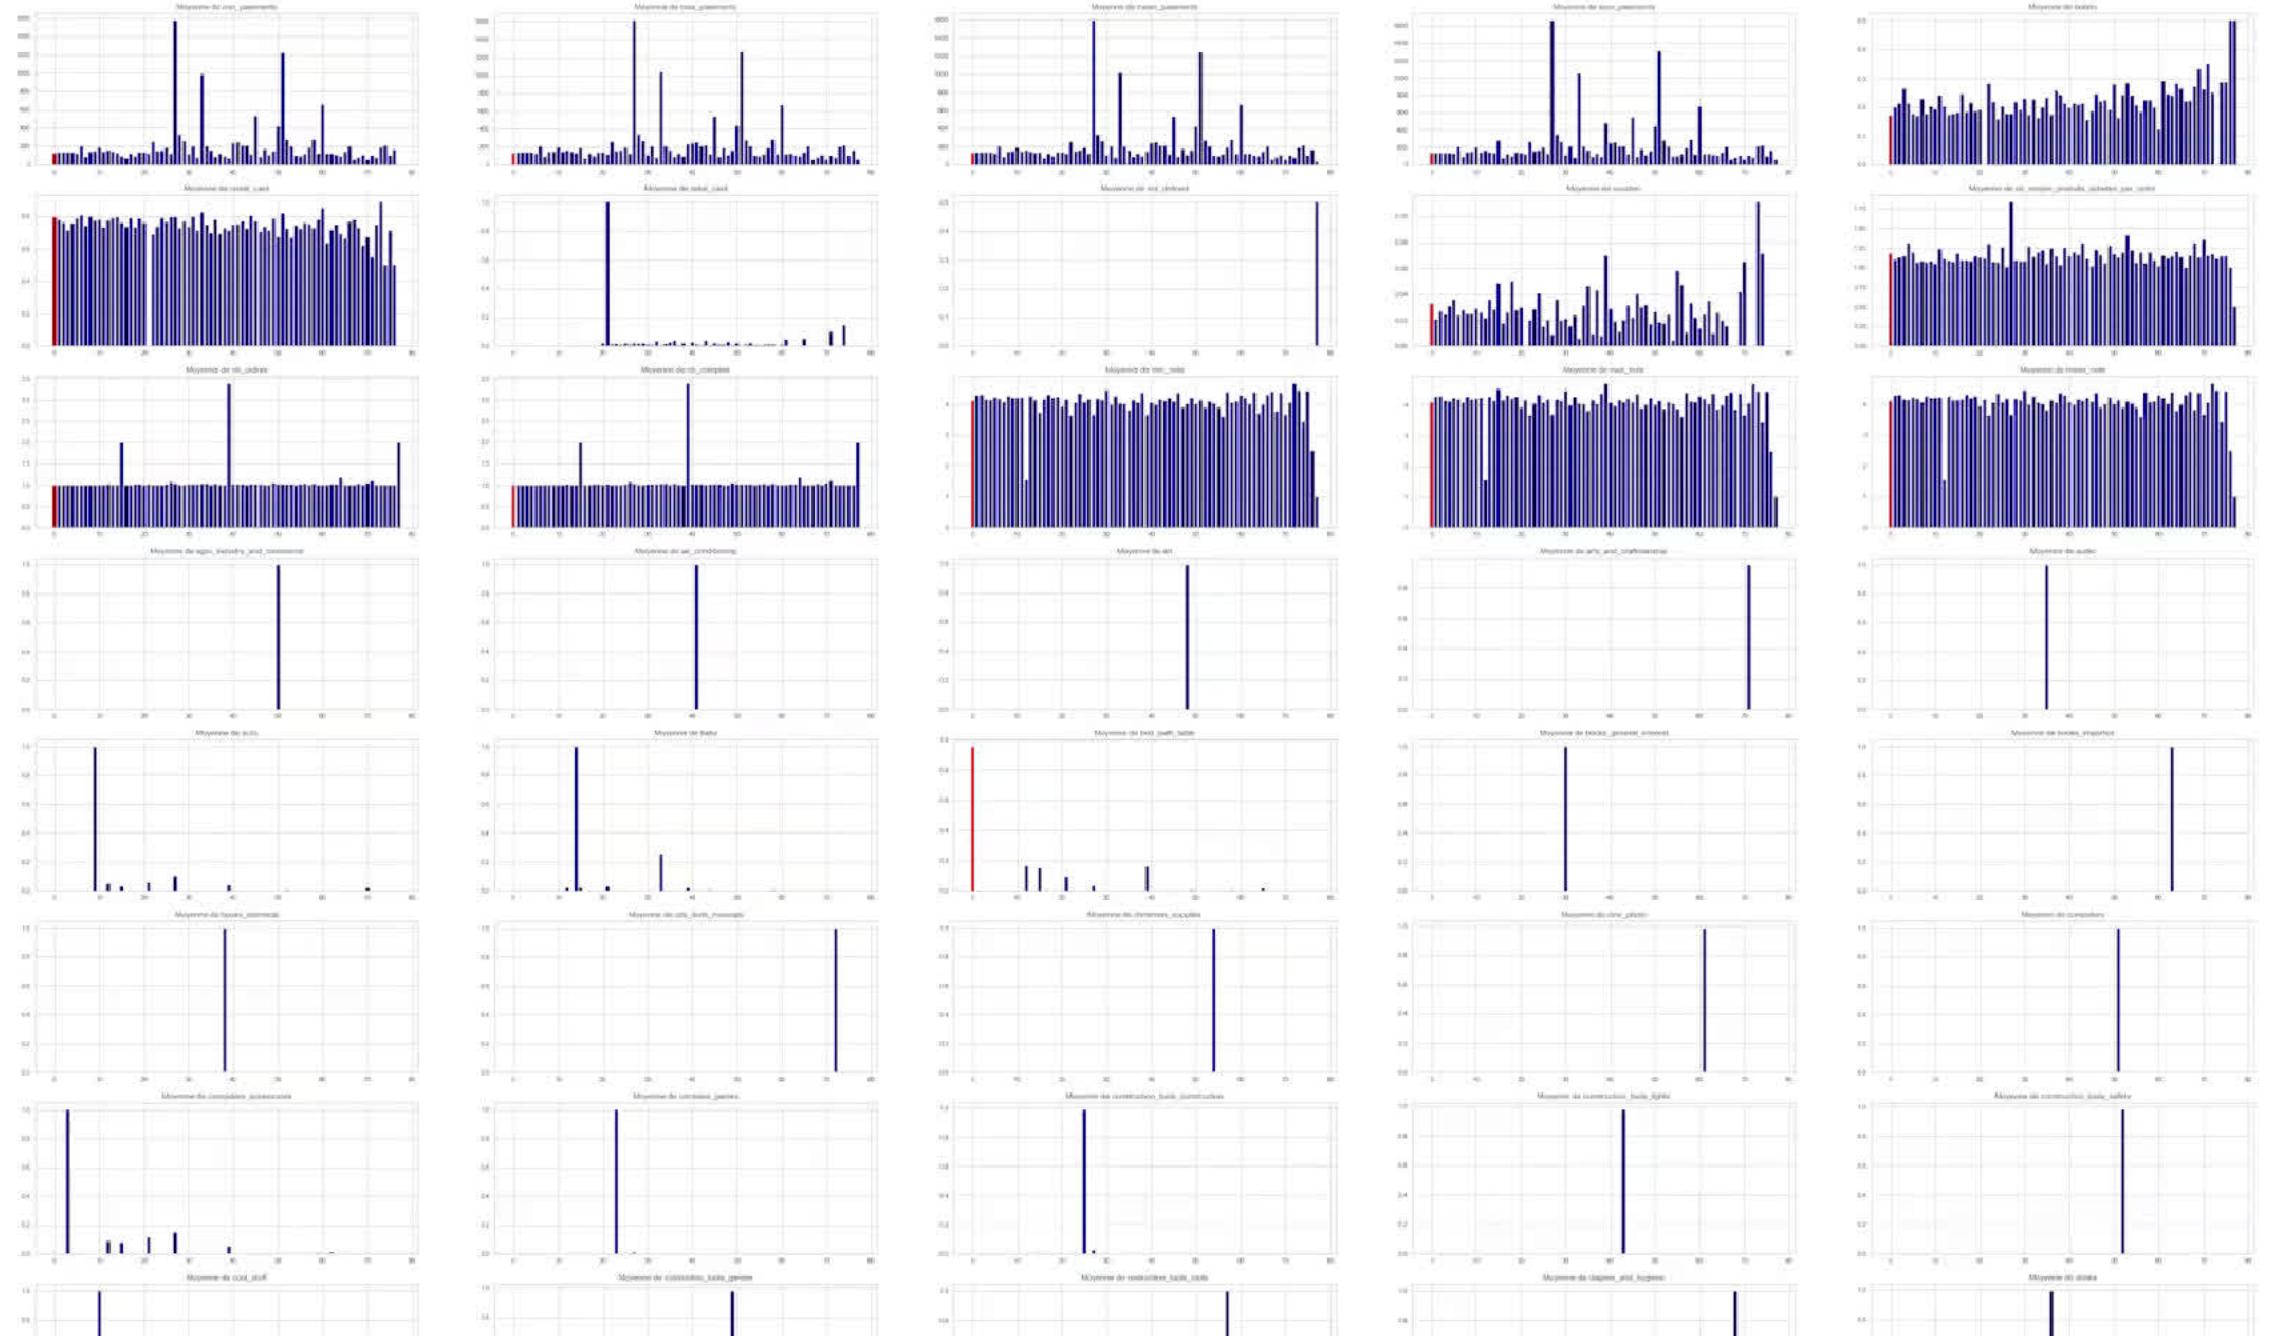
hyperparamètre
 $K = 78$

groupes

olist



Observations des clusters sur tous les descripteurs





N° Descripteurs importants

- 0. Bed_bath_table, furniture_mattress_and_upholstery,
- 1. home_confort
- 2. Health_beauty
- 3. sports_leisure
- 4. computers_accessories
- 5. furniture_decor
- 6. housewares
- 7. watches_gifts
- 8. telephony
- 9. toys
- 10. auto
- 11. cool_stuff
- 12. note_min, min_delivery_time, delais_livraisons_14_max, furniture_mattress_and_upholstery, home_confort, health_beauty,furniture_decor, bed_bath_table, computers_accessories, garden_tools, watches_gifts

- 13. perfumery
- 14. baby

-
- 27. min_paiements, max_paiements, mean_paiements, sum_paiements,nb_moyen_produits_achetes_par_ordre
- 39. nb_comptes, nb_ordres, sum_delivery_time

Description des clusters

— — Clients dépensiers dans une catégorie de produits ou dans un groupe de catégorie de produits

— — Clients ayant eu des délais de livraisons importants causes de faibles notes pour ces 8 catégories

— — Clients à fortes dépenses par commande

— — Clients qui commandent souvent

Projet 4

Thank you !

